

【前哨科技特训营 7 月 16 日】

主题：国产算力产业链扫描

（文字整理）

整理人：创新地图助手



第一部分：课程要点提炼

风险提示：以下内容均为产业分析与课堂观点整理，不构成任何投资建议。

本节课核心不是找“哪只芯片股能涨十倍”，而是判断国产算力产业链的真实机会与风险。

一句话结论：AI 算力需求是真实爆发，但国产算力机会会高度集中；训练看华为，推理是红海，第三梯队芯片公司进入淘汰赛，真正的长期机会会逐步转向多模态、Agent、AIGS（AI 生成服务）和全球化应用。

一、AI 不是泡沫，需求是真实市场拉动

1. 算力需求不是政策口号喊出来的，而是用户和市场用出来的。

2. 主要需求来自三类：

一是大厂内部提效。Meta/Facebook、谷歌、字节、腾讯等自带流量的平台，用 AI 优化广告、搜索、推荐，能直接变现；阿里在广告推荐效率提升上的直接弹性相对弱一些，因为淘宝流量更多依赖外部导入。

二是多模态增长。图片、音频、视频、短剧等需求继续上升，中国在视频数

【课程入口】公众号“全球风口”进入特训营

据和应用场景上有优势。

三是 AI 编程和 Agent 爆发。程序员、业务人员和普通用户大量使用，Token 消耗增长很快。

3. 关键判断是：需求来自真实使用，不是智算中心建出来的。

二、Scaling Law 没失效，中国基础模型仍会阶段性追赶

1. 模型能力仍在继续提升，基础模型竞争没有结束。

2. 只要国外模型还能持续跃迁，中国就可能在基础模型上阶段性处于“差半年到一年”的追赶状态。中国擅长工程化、性能调优和规模化落地，但这些优势最适合在技术革命放缓后发挥。

3. 现实打法不是全面冲 AGI，而是在细分领域集中资源，依靠数据优势、应用场景和工程化做 me-better，尤其在视频、多模态、应用出海上形成领先。

三、大模型公司会分化：大厂模型更有优势

1. 独立大模型公司如智谱、MiniMax、Kimi 等，难点在于持续研发要烧钱，但模型好不等于能赚钱；上市后市场不再只听 AGI 故事，会问收入、现金流和增长预期。

2. 大 IT 公司自有模型更有优势，因为字节、腾讯、阿里等有流量、业务和应用场景，模型投入能反哺广告、推荐、搜索、办公、编程等业务。

3. DeepSeek 是另一种逻辑：低价和开源能打开海外使用量，但使用量不等于收入回流，商业闭环仍需观察。

四、AGI 不会很快到来，未来关键是场景化数据

1. 现有互联网语料缺少场景、立场、过程，只剩“干巴巴的知识”，很难直接通向 AGI。

2. 课程强调 Situated Knowledge、Cultural AI 和 Distributed Cognition 这几个概念：未来真正重要的不是简单结果数据，而是过程数据、场景数据、行为数据，以及人和多个智能体协同形成的分布式认知。

3. 机器人、智能制造、健康数据和手机端行为智能，都需要重新采集过程与场景。

五、训练和推理正在分离，国产算力机会主要在推理

1. AI 算力分为训练和推理两个市场。

2. 训练需要万卡集群、强芯片、强通信和系统协同能力，本质是大规模工程问题；推理单个任务不一定需要万卡，百卡、小集群也能支撑，核心是高并发、低延迟和资源调度。

3. 国产训练芯片真正能打的主要是华为，未来两三年训练侧仍需要英伟达支撑；推理侧虽然打开了国产替代窗口，但商业上大客户不会轻易接受“七国八制”，会优先选择稳定、成熟、可规模交付的头部供应商。

六、国产芯片格局会高度集中，第三梯队进入淘汰赛

1. 国产 AI 芯片大致分三层：

第一梯队是华为，训练和推理都具备最强替代能力。

第二梯队是阿里平头哥、百度昆仑芯，以及未来可能出现的字节/高通合作方案，这类公司有云、有模型、有内部需求。

第三梯队是寒武纪、海光、摩尔线程、沐曦等独立芯片公司。第三梯队最大问题是没有足够内部需求，只能依赖外部采购，而未来大客户更倾向头部方案。

2. 因此，本节课最关键的风险判断是：第三梯队芯片公司不是比谁涨得多，而是比谁能活下来。

七、部分政府/运营商智算中心存在结构性过剩，大厂自建/主导算力是真实需求主线

1. 算力需求真实存在，但并不等于所有智算中心都有需求。

2. 部分政府/运营商主导的智算中心存在空置、利用率低和结构性过剩问题；真正算力紧张的是字节、腾讯、阿里、美团等头部互联网公司，因为它们有流量、有模型、有应用、有真实 Token 消耗。

3. 但这些大厂不是国家队，没有义务扶持第三梯队芯片公司，会优先选择华为、自研芯片或成熟稳定方案。因此，部分第三梯队依靠国家队订单支撑的逻辑，未来会逐渐减弱。

八、中国 AI 出海和应用侧，是更长期的机会

1. 中国开源模型在海外使用量增长很快，但使用量不等于收入回流。

2. 如果海外平台自行部署中国开源模型，用户消耗的是中国模型能力，但收入可能被第三方平台拿走。因此中国 AI 公司出海必须建立官方 API、海外品牌 and 用户直连关系。

3. 长期看，中国更大的机会不在继续追逐基础设施小票，而是在多模态、视频生成、AI 短剧、Agent、手机端 AIGS 和全球化应用。产业机会会从基础设施逐步向应用侧迁移。

九、产业判断与风险提示

1. 不能从“AI 算力需求增长”直接推导出“所有国产芯片公司都有长期价值”。产业增长会集中到头部，尾部公司会被淘汰。

2. 判断公司要看真实需求、大客户绑定、规模交付能力、产业话语权和估值是否能被未来收入支撑。

3. 课程的风险提示是：不要把小概率的高倍回报当成产业规律。国产算力不是没机会，而是机会越来越集中。

第二部分：课程文字稿

直播要点：

- 需求层**：平台广告推荐、多模态、编程等算力需求增长迅猛，AI算力已经成为需求拉动、健康发展的真实市场，未来还会进一步高速增长。
- 模型层**：Scaling law 没有失效，大模型仍需持续、巨额投资来支撑需求，独立上市的国产大模型公司处于劣势，互联网大公司更容易砸钱维持领先
- 模型层**：编程是全球统一需求，中国长期与国外有差距，多模态等细分领域中国有数据优势，有望在全球市场拿下份额；头部大模型公司能否做出细分定位，放弃AGI故事，是重要的未来信号
- 芯片层**：训练与推理正分裂成两个市场，训练本质是通讯/工程问题，依赖芯片和芯片集群；推理更多是性能调优与资源调度
- 芯片层**：训练看华为，推理市场红海化。制造与平台都将走向集中，华为依靠训练/推理将保持一梯队领先，大 IT 公司有望在推理市场进入二梯队，独立芯片公司将决战三梯队站位，同时面临国外厂商挑战
- 芯片层**：第三梯队企业当下面对的不是增长问题，2029年的淘汰赛已经启动，谁能存活才是关键

【王煜全】大家晚上好！今天声音应该清楚了。上次反映声音有噪音，后来发现是我电脑的风扇太响了，电脑太老了，所以刚换了个新电脑，谢谢你们的这个意见，促成我换了个新电脑，声音很好啊，应该不错，谢谢。好，我们今天的这个话题是国产的算力产业链的扫描，也是因为国内的这个芯片公司实在太多了，而且时不时还冒一个，而且估值都很高，所以这个大家就容易关注，那我们也就顺应民意，做做分析。但是坦白讲我自己个人觉得兴趣并不大。当然你说还是一

样的，从投资角度上说，如果投中了一个芯片公司，有好多倍的回报，当然话说回来，这也挺难的，因为上市的时候就千亿了。上市之后这几年，主要我们今天在讨论的时候会不会跌，而不是能涨多少？所以上市即巅峰。所以除非你做这个叫私募投资，没上市之前就投，要不然这样项目你也抓不住。

当然另一方面，私募我也其实不鼓励这种项目太多的其他的因素在起作用了，不是一个纯市场的东西。所以还是我们强调的，我自己能够有把握的是市场化的东西，市场上面，就是一切都由市场做主。这个企业在市场上会不会成功，我们可以有清晰的分析和判断。但如果加了很多新的东西，就不好说了，而我们大家特别喜欢瞄着那个新的东西去，然后我也觉得很困惑，我们不应该是挣自己能够确认的钱吗？为什么老想盯着那个百倍回报呢？如果这百倍回报根本是一个你不熟的领域，确实我没太听说过很多人说我从来没投过资，听了隔壁邻居说句话就投中了 100 倍股的，这基本上都存在于短剧里，都不在现实生活里。现实生活是我见到的都是这个第一投资的回报是个综合回报，不是看你投没投中百倍股，而是看你投的公司里面这个平均回报是多少，所以你投中一个百倍股，其他的赔个底掉，到最后未必有更高，对吧？第二个就是大多数成功的投资者都是在这个行业里深耕已久的。当然有人是专业做投资人，那就是专业看这个领域也看的很久了，而不是一个泛泛的投资者。我很少看见泛泛投资者成功的，所以我们还是强调聚焦，还是强调懂，挣你该挣的钱是吧？那当然还是一样，那你就说非得要看算力产业，我们也给大家分析。

首先说结论，第一个就是算力这个产业是真实存在的，很多人老担心说人工智能是不是泡沫，现在有明确的证明人工智能不是泡沫。第一个就是说大公司本身用人工智能来节能增效，尤其我们讲有流量的大公司，在用算力提高广告效率上效果是明显的，所以这个对它来说是有价值。包括国外的 Facebook、谷歌，包括中国的字节，包括腾讯，都是很明显的，当然你比如说阿里就有点小问题，为什么呢？阿里的流量不是自己内生的流量。阿里靠买流量，这种时候用算法来提升，优化空间就没那么大。而自带流量算法优化就会比较好。所以大家就能理解，在未来腾讯算法优化来提升自己的广告效率，就和国外 Facebook 一样，就会有比较好的效果。而字节也是一样，那就别忘了抖音对吧？就会非常好，我们自带流量，所以自带流量的时代这个人工智能会使得流量的效率能够提升，当然

这是一个。另外这个迅猛增长的包括多模态，意思就是不管你是制作音频、视频，画个画，做个视频等等等等，这方面需求还是挺旺盛的。AIGC 的需求并没有消失，还在继续往上涨。然后新的一个长得更快的需求起来了，叫做编程，包括编程两个方向，一个直接写程序，一个是做 Agent，用 Agent 来干别的事儿，生成 Agent、调整 Agent，这方面的需求都是非常迅速的。而且是草根的需求，不是某个大企业拉动的，而是一堆草根的需求。所以总的来说，这部分还是让我们很放心，而且需求还在扩大。第二个就是说需求层再往下，那就是模型来支持需求对吧？那从模型层角度来讲，就是 Scaling Law 没有失效，还会进一步地提升，也就是说模型能力还有进一步提升，包括我们说你看 Mythos 起来以后，很快这个 OpenAI 又在应战了，它的性能也在提升。甚至说中国也有人在说我能不能半年达到这个 Mythos 水平，是不是半年能达到，不确定，但是这个可能性还是很大的。那另外一方面，就是国外有 Claude Code，那立刻就有个 Codex，而且 Codex 增长也很迅猛。所以你看这最热的领域，编程和做 Agent 这方面的大模型，内容生成和编程这两个领域，并不是能够长期一枝独秀的，有人领先，时不时还有突破存在，但是很快别人就会跟上，当然我们也希望中国能够快速跟上，那就意味着什么呢？意味着这个基础层的竞争、能力层的竞争还没有停止。当然对中国来说就不是一个特别好的消息，因为中国擅长工程化。那工程什么时候会有最大的效果？最大的价值？就是能力竞争已经基本结束了，就是这个能力不提升了，那剩下就节能增效了。但是如果能力还提升，节能增效就不是最重要的。因为我继续提升能力，比节能增效只能提升一个百分比的效率，但是提升能力可能能翻倍。

所以只要是 Scaling Law 存在，当然就是能力提升是第一位的，所以这种时候就带来一个事儿，就是说中国长期可能还要处于追赶状态。就是我们可能是在国外有一个大的突破，比如 Mythos 来了，我们跟人家这个差距会拉远一点。那经过半年一年慢慢的适应，我们差距会拉近。但是可能一年之后又有一个什么突破，又会拉远。所以就是我们可能永远比别人还差半年到一年，在跟着，就很难突破。因为如果说一旦这个大模型的进化，尤其是技术的进化停滞了，那就看谁的这个性能能够更进一步优化，甚至谁能够打出组合拳来，就是从技术到应用能够出彩。别忘了这个生物医药里我们的例子，人家有这个先进的生物药叫

first-in-class, 我们可以有 me-too, 当然美国也做 me-too, 中美都会做, 所以但是我们甚至还可以有 me-better, 我把两个抗体联系到一起, 把不同的药品的机制联系到一起, 我就可以做更多的多样组合, 所以这个是中国擅长的在工程上取得领先, 但是这个前提是技术的革命逐渐停滞, 或者说最起码趋缓。如果技术革命特别快的时候, 那工程领先就不够。因为我说了它只是一个百分比, 不可能翻倍, 所以这个是我们中国的规模化上有优势, 但是我们要切入的时机很重要。当然不可能被甩下, 因为中美还有一个竞争的问题, 所以造成了中国我们就要关注这个世界的大模型的前沿, 中国在什么点上去切入比较好啊, 这个都很重要。

回过头来说, 这是一方面, 就是中国在全球如何选自己的战略和这个定位的问题。就是也不能什么都做, 而且要知道说在哪些领域我们可能至少阶段性的不能领先, 所以要有相应的这个策略去应对。另外一方面也很重要, 就是因为技术还在迭代, 那我们也不得不跟进, 就意味着还要持续的要有钱, 要有投入来支持。就不是说现在就直接生产赚钱了, 还要大量研发投入, 而且这个 Scaling Law 意味着研发投入不会小。研发投入不小的情况之下, 就中国能跟得上这么大研发的公司也就屈指可数了。实际上我说得再坦白点, 就会使得现在已经上市了的中国的大模型公司, 他们会处于不利的局面。如果没上市的时候, 我甚至还可能融巨资, 为什么呢? 因为我在融巨资, 只要你上市的时候, 那个上市的估值很高, 那我的融资就值了, 我的投资就值了。所以巨资也是投得进去的对吧? 比如说我哪怕我投了 100 亿, 占了你的 20%, 但是这个就意味着你估值是 500 亿, 对吧? 但是如果你上市的时候, 市值是 2000 亿, 那我就赚四倍, 这件事儿不是没发生过, 最早就是李嘉诚投 Facebook, 当时 Facebook 已经是百亿市值了。当时人人都认为 Facebook 2008 年的时候, Facebook 百亿美金估值的时候, 李嘉诚投了五个亿美金, 占了 5%。当时人人都觉得这个瞎闹, 这个不太现实。结果到了 2012 年 Facebook 上市的时候, 市值两千亿美金, 直接 20 倍, 所以一直老说小超人, 李泽楷说是互联网做得好, 结果他爹反倒是更厉害, 一战成名, 就是投了个 Facebook 比他儿子投的所有钱赚的都多, 因为一下百亿回报, 所以这个是可能的, 但是这个前提是什么呢? 就是只要你涨得上去, 那么问题来了, 就是等到你上完市了以后, 你能不能再融到百亿对吧? 这就问题就来了, 这就相当于说你看你上市之前, 你估值是百亿, 能融几个亿, 这没问题。因为我知道你还会

涨，但如果你已经是千亿市值上市了，你再融百亿，那人家就一定要问你说我凭什么给你这百亿？那就是你能不能有进一步的扩张，因为我会要求那么高的回报，这就很难了。也就是说实际上上市后的融资是两说的。第一个融资会有便利性，为什么？因为上市有流动性，就是我融完资了以后，他这个投资者可以随时可以走，他有流动性，他不会被锁死。但是如果你是上市前融资，它这个你实际上是叫 paper money，就是会被套牢的。就是你如果估值下跌了，这投资人也没办法对吧？但如果是上市，可以及时止损，你如果股价低了，我就跑了，对吧？所以有流动性，这是一个巨大的优势。但是最大的问题在哪呢？就是我对你的预期也会高上去，就是你如果没有增长，我也不会投你，所以还是要有增长的预期的。那如果你已经是一个，尤其是现在很多公司，就我们说上市即巅峰，你上市的时候这个估值就已经严重高估了。那你的增长预期在哪儿呢？如果没有增长预期，你怎么能融到资呢？尤其融到大资，你讲不出去这个故事了，那这种时候就会有问题。

所以坦白讲，上市融资既有它好的一面，也有它很严苛的一面。就是人家已经不听你讲故事了，直接问现金流在哪儿，很现实了，上市就已经很现实了。所以这种时候就意味着什么？意味着国内独立的大模型公司，如果你说我就是为了融资继续优化我的大模型，坦白讲可能融不来这个钱。因为人说我为什么要帮你来优化你的大模型，而且你优化完大模型能不能赚到钱，这是两码事，大模型再好不代表能有钱挣，所以这个对于他来说就很难。但是我们刚才说过了，因为很多大 IT 公司本身为了维持自己的广告推荐效率，我就能赚更多钱，所以我就一定会砸钱做大模型。所以我们说还是之前说那个逻辑，大模型公司在中国分成两类。一类是独立的大模型公司，包括像智谱、MiniMax、Kimi，对吧？另一类就是大 IT 公司拥有的就是像通义千问、像豆包这些，那现在看起来那就后者更有优势。当然更有优势，再细分的话，就是对自己公司更有助力的，就容易得到更多的支持。所以通义千问也很难，就在这儿。因为通义千问本身对阿里的助力，就不见得比，比如说字节更大。然后再往下模型层还有另一个就是就要进入细分市场了，就要看钱在哪儿了，对吧？那么钱在哪儿呢？就是一个是叫做编程，但是编程的钱注意未必好拿，为什么？因为编程是全球统一的，而且中国人学编程也都上来用的英文，编程的基本语言理论上是程序语言，但是很多是英文词儿，

所以这个编程是全球统一的。所以就是别的地方，你比如说叫这个芯片，人家不
对你出口，中国好替代进口是有机会的。但是编程这块，当然了像 Anthropic
这样的甚至也不愿意出口，那是另一回事。但是大多数他不会那么防着你，他愿
意让你用。那这种时候就替代进口就未必成立，因为我一定要用最好的，而不是
我只能用到这个国产。包括就像我们这样举的例子，这样文字编辑、文字处理中
国其实最早有 WPS，就是金山最早做的。但是我们都知，后来都被 Word 给统
一掉了，为什么呢？人家做的好就有通吃的机会，因为一个道理就是表面上讲是
中国人说中文写中文。但是中文的文字处理的平台软件和英文文字处理的软件的
差异并不大，就是除了全角、半角的比较。你到底是八位字符还是 16 位字符，
其实没多大区别，处理起来底层的计算逻辑是一回事儿。所以这种时候国外的领
先就容易持续，也容易渗透到中国来。所以这个是我们要小心小心的，就简单的
说编程优势，中国要面对全球竞争，然后另外一个就是多模态，这个注意中国有
明确的优势，为什么？因为多模态需要什么数据训练，数据在谁手里？就是你要
又有数据，又能够有这个大模型，你就有优势。美国虽然比如 OpenAI 领先，之
前它早就用的是 YouTube 数据，对吧？而且当然美国也相对开放性还是好一点。
中国你看这个尤其是叫视觉处理的平台，主要还是抖音和快手。为什么？就是人
家手里有大量的视频，那我就容易做视频的训练，所以简单说就是多模态，就像
视频这里面中国可能会长期领先。因为我们这个有数据，而且我们有数据的公司
自己可以做模型。另一方面来讲，就是全世界有需求，就视觉处理是有需求的，
而且再加上这个需求主要来自于中国在往世界扩散，这个逻辑是正确的。所以我
们认为很有可能在长期来看，就在视频生成视频处理这块，中国是有优势的，但
是这里面有个问题，就是我们刚才讲过了，就是 Scaling Law 没有失效，人家的
领先性就依然还在，因为你已经领跑。这么说，如果我们还天天说着这个所
谓叫做 AGI 对吧？包括前一段有个公司的 CEO 说，如果没实现 AGI 我就不领
工资，那我就觉得恭喜你基本上你未来的 20 年都领不着工资了，对吧？这个实
现不了，而且何况是一个独立的大模型公司，声称说我要主打实现 AGI，我觉得
这不现实。第一，中国的独立大模型公司又没有国外那么强的融资能力。第二我
还面临着更强大的竞争，对吧？你怎么都不太像靠自己的财力能在中国实现这个
AGI 的。当然顺便说多说一句，我改天有时间再跟大家讲。最近我一直在研究这

个人机如何融合，就是说叫 cyborg intelligence，有些心得有空跟大家讲。但是因为现在也越来越现实。当然我不知道大家喜不喜欢，但我不喜欢，大家都是要结合哪个市场，哪个企业，哪个用户，就希望每次来能听哪个公司我可以投资，但是我是希望谈未来这个世界的规则是什么的，所以这个人机融合是未来一个特别重要的规则，我也花了很多时间精力来研究这个，还是蛮有心得的，那甚至这个就是要我们每个人就要做到这一点，所以叫新物种。你就要做到这点，那这个就是能够更好地和机器去融合。因为我们的认知是一个完整体系，要把这个人工智能嵌入到我们的认知里面去才能做得好。反过来讲，也是要有人工智能和人的协同，才能形成更好的认知。当然另一方面也是这个核心，就是说我们的认知的理解在进步，就是人的认知是怎么回事，因为我们去研究机器要怎么能够认知，怎么能够形成理解。大家记不记得我之前讲的叫这个人的认知，之前讲的 Jeff Hawkins，叫记忆预测结构。国外科学家有人在研究说叫这个机器的认知，很像，这个叫什么？叫 perception-action，perception 就是我对世界的预期，就是预测。但只加一个预测不够，完了以后，因为我要和世界互动，要有行动，这个行动要有结果，结果回来再回到我的这个预期当中来，或者回到我对世界的认知当中来。所以我们强调这个世界的认知叫记忆预测结构是错的，那个记忆是错的，应该叫认知预测结构。

我们人特别有意思，我们先天对任何东西，上来就需要先形成一个认知，我们才行动的那当然有人鲁莽，连认知都没有完全形成就行动了。有人就谨慎点形成完整的认知，真搞懂了再行动，所以叫谋定后动。那是要先有认知，认知之后行动，这是所有动物的天性，天生就会这么干，这不需要训练。甚至到什么地步，就是我们去我不知道大家关注过没有，我们去任何一个新的社会或者一个新的团体。你就会下意识的去观察这团体里这个规则是什么。比如说他是守社会规则的，就是讲道德讲礼仪的，还是赢家通吃的古代斯巴达，这个胜者为王的，然后有没有长幼尊卑，有没有最强者，谁是头儿，谁说话算话、信用程度，大家看不看重信用等等等等，这些东西都会综合评估，我就慢慢都会把这些总结出来。就是我们看一个社会的时候，上来就会有一个综合评估体系。我们这么去看这社会，我们就会觉得，我一看了以后，这个社会是等级森严的，这个社会是不鼓励创新的，这个社会谁谁是头，那你就先去拜访这个拜码头，先听他的，这个我们就能够适

应。所以就是说我们对任何东西的理解，从具象世界的理解，哪高、哪低、哪有水、哪有树，到抽象世界的理解。一个社会里社会规则是什么？社会系统结构是什么？社会的头儿是谁？那就是高山，那谁是底层，就是所谓印度的不同的种姓等等等等。就上来就会形成这样一个判断，然后我再用这个判断就会生成 perception，就我的预期如果我做了什么事儿会有什么反馈，然后我再这么去做，看是不是得到这个反馈。你发现没有？是不是和 FSD 的训练特别像，所以一定都是这样的。

所以悦行远方问的非常好，未来人机共生也会有人情世故。就是我要回答的问题就是因为 AGI 为什么在 AIGC 时代实现不了？注意，因为这个有一个特别有意思的说法，有个词儿大家有兴趣去挖一挖，叫做 situated knowledge。那叫做 situation 的意思是位置，就是这个位置化的知识什么意思呢？或者叫立场化的知识，不叫位置，叫立场化知识。什么意思？就是我说这句话的时候有我的立场，对吧？我的立场是什么？我希望就是我看到了一些世界前沿，希望分享给大家，希望大家都能够好。但是这个立场不会天天说，甚至有的人的这个立场都没有表达出来。别人在说一个问题，有别人的立场，就是每个人说话都有潜台词，都是立场。AIGC 是什么？不叫 AGI，叫 AIGC。就是上一轮的人工智能基于什么？基于对全世界互联网数据的收集，对不对？但是你发现没有互联网数据，它把你的立场放上去了吗？没放上去是不是？就我说这句话的时候，我只是这句话搁到互联网上被传播了。但是我背后我说话的原因，逻辑系统都没有，对吧？那么意味着丢了东西了。就当世界所有人的立场场景化的知识，这个场景部分都被抹除以后，只剩了干巴巴的知识。然后你把它提炼，你提炼不出真实世界。也就是说基于现在的内容生成的这个系统，不可能形成对真实世界的认知，所以这个是很重要的。那么反过来讲，就是我们很快大家就会验证我说的到底对不对。为什么？怎么验证呢？因为很快有一个地方就必须要结合这个情景。这个 Patrick 说的比较好叫情景或者叫场景化的知识特别重要。那就一个东西就需要场景是什么？就是机器人。就是说因为我们在内容生成这方面，你把场景去掉了以后，你还可以，最起码能生成内容，做互动。但是在机器人如果把场景去掉了以后，那就只剩，大家注意到，我没有说这个机器臂不行，机器臂在干一个独立工作的时候，它可以去掉场景。因为那场景已经设定好了。比如说我就两只机器

臂，给我冲咖啡，这是一个确定的场景，我就可以做事儿了。但是如果是一个开放场景，我就要首先理解这个场景，这个背景，理解这些人。也就是说很快这个机器人就会知道说我要理解场景的核心根本不是所谓 Physical AI，不是这个三维物理世界是什么，而是 Cultural AI，是这个世界的文化背后它代表着什么，更重要对吧？所以你不是只是认出这个物理实体而已。是比如说看到我的桌子上支了个显示器，那看的不是显示器，是看显示器上显示的是什么，这些人在干什么，所以这些的背景知识都非常重要。

简单说就是我们现在之所以不可能形成对世界的真实理解，因为我们用于训练形成对世界理解的模型的这些数据是被严重的抽象过的，它是脱离现实的。你给了一个不现实的场景，怎么可能形成对真实性的认知呢？这不可能的，所以未来我们就讲了虽然大量的，所谓叫机器人数据采集公司已经出现了，这我们早就讲过，机器人公司出来以后，数据采集一定是个热点，现在已经一堆了。但是数据采集的规范 and 标准都没有通用化。也就是说你只采集这个数据没有用，你关键是要采集数据的什么场景，什么背景。特斯拉 FSD 理论上是接近的，它叫这个 situated knowledge 叫立场化的知识。简单说就是我们未来对这个世界的理解，需要有更多的数据源数据输入。而这数据输入需要重新采，不光能够采数据本身，而且采背景、采立场、采过程。这回我们上周去无锡去考察。无锡考察，我们考察了一个为汽车产业做配套的测试仪器仪表的一个企业。他们就强调讲到说，当他们在做人工智能的时候，做智能化改造的时候。他原来觉得说你看我本来就是一个挺数字化做的挺好的公司。无外乎我把所有的数据都提供给人工智能，它帮我做智能化不就行了吗？后来发现说这事儿想简单了，为什么呢？因为智能化需要的数据不是他以前采的那些数据，他就说我以前采都是结果数据，就是说这个没关系。老给我揭秘，万耐特，这个非常棒的公司，非常棒。他说的是我以前采的数据都是结果。但实际上人工智能要理解这数据，要知道过程，就要知道数据要有过程，把过程数据采集下来，才能用人工智能去训练。我以前就根本就没采集，我以为是只要采集从 A 点到 B 点，只有 A 和 B 就好了。但是实际上我要记录是怎么从 A 到 B 的。比如运行的轨迹、场景，是被什么东西携带的、抓取的对吧？都要知道才行。所以你看大家就知道了，就是未来的大量的数据都要重新采，这才是真正的未来，不是指今天的東西对吧？所以说远了直接说结论，就

是今天千万不要高估我们对这个智能的理解，或者说什么 AGI 早得很。我觉得三五年的时间，大家一定会重新对人的智慧肃然起敬。因为突然发现我们其实忽略掉了很多很多东西，我们要实现下一代飞跃，要实现对人的智慧的理解。但是怎么能够对人的智慧有更深入的理解？就是恰恰是在训练人工智能的时候才知道，因为那些东西是我们做不到的，才知道人的智慧没那么简单。我们训练小朋友就能做到，训练人工智能就做不到，说明你小朋友还是有比人工智能强的地方的，所以那到底是什么？但是反过来讲，当我们能训练人工智能做到很多事的时候，我们就知道对智慧的理解。因为人工智能无疑是已经有智慧了。我们现在就是智慧的理解在越来越加深。但是智慧理解加深以后，未来变成什么呢？第一个就是智慧是场景化的。从而当它能够场景化的时候，注意当你能够理解场景的时候，你对智慧理解也会加深。而且当你的场景有智能性的时候，就是当你的这个工具。我们强调是什么呢？就是我们的智慧是一个连续过程，智慧是在过程里，而不是一个结果。不是说我看了 $1+1$ 就直接得到 2，而是我后面有一个运算系统，能够把 $1+1$ 得到 2。但是有很多运算系统不是体内的，是和社会环境、工具相关的。那当我的社会环境、工具有了智能的时候，我的整个智能的思考体系，我的智慧生成体系要变化。这会变成叫人机的真正的协同。

就是当我的思考里面含了很多的这不是由我完成的，而是由人工智能来完成的部分，而且是和我的思考、我的人完成的部分和人工智能完成部分是有机整合到一起的。最后得到一个结论，这才是真正的人机结合的未来，真正的 cyborg，这部分是特别重要的。第二个就是甚至说当我和环境都能够形成一个整体，从而形成这个思考能力提升的时候，那就意味着不光是我。因为本身我们人很多思考也和社会是相关的对吧？我们的社会环境也很重要。未来就不光社会环境，而是生态环境。因为我周围有很多很多的智能体能协助帮我提供信息，来帮我形成认知，包括甚至帮我形成反馈，形成我的新的思想。而同时也就意味着什么呢？是另一个词儿，叫做分布式的知识，就是人的知识也不光是 situated，而且基于环境的，而且是这个分布式的，也就是说还是我们强调那个智慧存在每个人的脑子里，而不存在一个集中的东西，都不是知识了，叫这个很有意思，叫 distributed cognition，叫做分布式的认知，distributed cognition，所以今天给大家提供两个新词儿，我给你打在这儿，这就是你知道我为什么觉得兴奋

呢？这不就是给我们大家提供了一个我上次讲的如何去挑战 Anthropic 的机会，Anthropic 已经是一个集中式知识的，集中式认知的集大成了，那我们怎么能够能够打败他呢？就用这个叫分布式认知来打败他，这个特别重要，稍微说的远了一点。但是还有另一个词儿叫做 situated knowledge，叫立场性知识。这两个词儿打在这儿，大家可以花时间多琢磨，这就是未来，人机融合，而且不是一个人和一个机，是 N 个人和 N 个机器的系统融合，而且不是生硬的融合，说你干你的，我干我的。而是在整个认知流程里，有些人干，有些是人工智能干，混合到了一起，是一个流程形成认知。而同时这个人机融合里面又是各自完成各自认知，形成分布式的认知。这就是未来，这里面需要大量的工具，需要大量的方法论，需要大量的帮手，对吧？所以这是我真正感兴趣的，这是未来世界的关键，而不是那些具体的，就是当你懂了战略的时候，你能自己推出来战术应该怎么做，而不需要我们来告诉你战术一步一步怎么做。因为那个是太简单的事了。

说远了，回过头来说就是大家就知道了模型层我们在这些基础能力上，基础认知上尚有欠缺，不太可能形成 AGI 的突破。但是问题来了，因为中美急需竞争，人工智能的竞争，美国一忽悠，中国也容易跟着。你都觉得这个必须要对抗了，我也得对抗，美国讲 AGI，中国也讲 AGI，意味着什么呢？尤其是那一家讲 AGI 那你想我们的很多的人工智能创业公司，就以这个实现 AGI 为己任，他其实就错了，因为他实现不了，理论上你觉得我就是用这来创业的，我肯定技术水平更高，更容易实现 AGI。但是其实它的财力更薄弱，实际上 AGI 还要靠钱砸，所以更有危险。所以我们就说头部的大模型公司，尤其是独立的大模型创业公司，未来几年，如果这个 CEO 天天讲 AGI 故事，这人就悬了，这个公司就悬了。如果不讲 AGI 故事，我就是好好地在国外做视频生成，我觉得这事儿是靠谱的，能赚钱。这个是谁？刚才群里有同学已经说了，我就不批评这个人工智能创业者了。

好，这是模型层。再往下是芯片层。芯片层也特别明显。因为我们支持的这个应用在井喷式增长，应用要实现，分成两部分，叫训练和推理，那现在训练和推理正在很清晰分开，一部分就是训练，训练的本质是个通讯和工程问题，主要这块要芯片足够强，然后还有芯片集群足够大，所以叫万卡集群，讲究这东西。

而推理，实际上理论上讲，我就不需要 1 万个卡来实现推理。因为推理任务一个一个小任务，训练是个巨大的任务，是不能分割的。因为你同时训练一个模型，你那个多少都是上万亿的这个参数都要同步的调整的，而我是推理，我什么都不动了，剩下就是有什么输入给什么结果，所以基本上百卡就够，小集群。表面看我是一个万卡的推理的计算中心，那也是 100 个百卡，不需要一万卡同时来协同。所以这种时候就是简单点听起来大家就会觉得那个可以，那小的公司做推理芯片可以生存七国八制，我只要在里面凑一份就行。但是很不幸，注意很不幸，这个不是这样的。为什么？因为我们以前，大家记不记得？当然我为什么要给大家讲这个讲座呢？也是因为这之前我传递了一个有点偏差的信号，这会要纠正。大家记不记得之前我上次讲这个芯片上，我讲过中国的芯片分成三个梯队。

第一梯队是华为，当然整个来说都是为了替代英伟达，现在看起来我们都知道 H2 是正在谈判进中国的问题，就是理论上讲的，今年很有可能还是会达成。因为现在看起来训练是还是需要英伟达的，这个立刻替代英伟达的可能性不大。所以我们很可能今年还是会进口 H2 的。而且我认为理性的讲是该进口的就是训练还是要靠英伟达。唯一能够对英伟达形成一定的替代的是华为，其他的都不行。所以这个芯片第一梯队只有华为一家在中国。第二梯队就是阿里平头哥和百度昆仑芯，当然理论上讲的就是大 IT 公司很可能是形成第二梯队，独立芯片公司都是第三梯队。我们之前讲的就是在国家主导的计算中心的建设上，基本上都是 80/20。第一第二梯队占 80%，总会给第三梯队留 20%、10%让你们分一分，所以各自能够分到一杯羹，现在问题来了，对吧？

这个前提是什么？注意前提是什么？是国家主导的计算中心建设，对不对？但是今天我就可以明确告诉你，算力需求确实在井喷，但是国家主导的计算中心会出现持续的算力过剩。也就是说如果你希望帮国家建计算资源中心，这事就别干了，因为它会算力过剩。但是如果你希望去帮这个字节计算中心，这事儿可以干的。因为它算力需求是持续的，是供应不足，需求紧张。但是问题是字节也找不着你干，干嘛不自己干，非得找你干，所以这时候注意我们今天给大家一个明确的判断，虽然是两块儿的市场，一块儿是政府主导的，通过运营商来建立计算中心，来建立算力中心的。但是这个市场因为没需求，所以这个市场是长期需求不足。第二个是一个就是以头部的 IT 公司主导的，就包括字节，包括阿里，包

括腾讯，这些他们主导的那这个是长期的，需求是不能得到满足的，需要持续建设，需要持续投入。而且这种建设投入基本上是汇总起来是千亿级别的，是很大的市场。

但是问题来了，就是这些人家是商业公司，人家没有义务扶持第三梯队。它不是国家队对吧？它没有义务扶持第三梯队，而且它会尽量避免扶持第三梯队。因为是麻烦。就是你想看，虽然理论上推理侧可以是你有 100 个卡插进来就可以跟我来协同，但是总会有给我增加一些负担，我干嘛要增加呢？总比这个全用一个公司要差要乱，所以也就是说简单的说就是大的 IT 公司在建设自己的算力集群的时候，会倾向于给头部企业，向头部企业倾斜就完了。另一件事，我们后面也会讲到，就是包括美国也是，美国原来这个台积电也是谁家的生意都接的。但是随着我们都知道，随着英伟达的迅速崛起，大家知道说现在台积电占 50% 的生产能力给了英伟达，他肯定不能给更多了，太疯狂了对吧？已经 50% 给了英伟达。但是中国的任何一个头部在中芯国际的那一块儿，最多占到 3% 点几，也就是差的远的很。就是中国还没有形成芯片头部集中。那好，芯片头部这个谁能形成，就是阿里，当然更大的就是华为，那一旦头部形成了以后，那肯定是最起码你是华为、阿里以外的另外一些能够在这个中芯国际拿到足够大的生产的份额的这样的企业里才能生存，要不然的话，我本来生产这个，甚至都没有那么大需求，排不上号。生产这个中芯国际都排不上期，那谁会采购他的芯片，不可能的事儿。所以简单说就是未来我们认为到 2029 年很有可能，当然也可能到 30 年，因为中国没有这么一个大跳水，所以也有可能 2029 年，也有可能 2030 年。但是芯片公司会逐渐有淘汰赛，这个淘汰赛已经开始了。注意芯片公司淘汰赛已经开始了，对吧？

然后郑新芬说为什么不卖给商业公司，指的什么不卖给商业公司？我没听懂，你说是芯片不卖给商业公司吗？这个芯片的核心是要做成计算中心，计算中心的建设是要么就是政府建，要么就是大 IT 公司建。他也会买芯片，他肯定买大芯片公司的芯片不买小的，所以我们这个问题是什么？国家队建计算中心不卖给商业公司。你见过什么国家队大量卖给商业公司的。第一个这个基本原则叫国进民退，这是未来 20 年的基本原则。第二个就是你建的计算中心，你卖给我合格吗？租都不一定合格的，就是你按你的需求建的。你卖也好，租也好，合格吗？而且

如果出租多余算力，注意，还能影响规划问题。如果我是这个字节，我不会，我知道这个算力短缺？字节对算力短缺的理解要比国企深入得多，我早就有理解，我就会规划了，这儿买、那儿买，唯一一个需求，我跟你说他们一定会倒腾，但是这个公开没法说，我只是稍微说出一点点，就是说这些大 IT 公司，大家记不得最近老有传言，其实虽然各种的封禁，但是总有各种芯片能进到国内，对不对？这各种的传言吧，甚至说这个数量不小，那你猜他进到国内给了谁了，那肯定不是给国家队建的计算中心，国家队建的计算中心消化不了这个没有正经来源的英伟达芯片，你说出去你得招标，你得透明，你国家要审计的，你怎么通过？但是你是大 IT 公司，对不对？这我不能再说的更透明了，大家懂的应该就都懂了，如果你不懂，你再找我，所以简单来说，第一就是 IT 公司一定是按自己的思路来建设，我才不买国家队，国家队建设也未必能让我看得上。第二个我即使买，我不买你算力中心，买你的芯片，但是你们家芯片我要买的是英伟达，而且我有办法能搞到，对吧？你们家芯片又不是英伟达，因为国产招标它一堆的事儿，那我为什么要用你的呢？对不对？

科技特训营

回顾：从生态形成到平行体系的算力供给



所以简单说就是可能偶尔有一两个小案例，国家队用打骨折的价钱把计算中心卖给了某 IT 公司，但是这会非常罕见，因为有各种的问题存在，那租更不用说了，就是这各种问题存在，所以这都是一个设想，但是不可能推动，好吧？然后我们说这个芯片就是两层，对吧？一个是训练，一个是推理。训练就是英伟达、华为，推理就一堆公司，但是未来几年推理的头部能活下去，推理的后面的公司都会死，而且今天推理的第三梯队上来都声称是想往训练走的，只不过走不到，

[【课程入口】](#) 公众号“全球风口”进入特训营

只能走到推理。至于说今天还声称如果还要做新推理芯片，你就知道说他的生存有多艰难了，所以要很小心。所以未来的故事是什么？未来的故事就是推理芯片提供商的淘汰赛，这淘汰赛的核心是什么？就是上量。虽然表面看在从技术上不需要上量，但是从采购上讲是需要上量。我才能相信你，你才有案例，我才能够把你接进来，当然需求是很明确的，这个是长期的需求，所以这是今天讲的核心推理，所以这就又回来了。我讲的东西我只讲产业，我不关心投资。产业的投资你都不喜欢，因为没投资机会，推理的绝对头部就是华为，你没机会投资，推理的另外头部就是阿里平头哥，就是百度昆仑芯，那这个寒武纪能不能成为推理头部，就看这两年的工作了。这后面我其实会列出来，一会儿到那我给大家讲，至于说后面的就别惦记了，这就好多人经常问我说我怎么样？包括昨天在群里聊天，有朋友说我最近这个持仓不太好，我告诉你看公司。我问了一句，我也嘴欠问了一句，就是持仓的是什么公司，他就给我列出来，确实挺好的，很真诚。但是我就没吭声了。然后同学还误解了，说你看一说了，你就没法回答了，我不是没法回答，我想说的明确点就是好多公司我都没听说过。很简单，我没听说过公司，你其实至少在技术领域大多数都不值得惦记。你想我天天看科技公司的，如果这家公司我都没听说过，大多数不值得惦记。就是你说这些所谓的不值得惦记公司，第一有没有黑马呢？可能有但这个概率极低。因为就意味着我关注科技，你科技真强我就关注到了，当然你说不是，你看我是这个光通信的黑马，我后面给你讲到光通信在整个系统里面越来越不重要，注意越来越不重要。所以别跟我讲光模块，那个光模块不是个事儿。当然你说有啊有些公司，比如我们上次讲，有个公司暴涨好几百倍，那叫什么呢？叫运气。就是说它是被带涨的，尤其是你原来根本就不被看好，是整个市场涨的，要把你带起来，那你确实能涨。但是这种东西这个概率根本就是命运不攥在他自己手里。那如果你赌一个命运不攥在自己手里的人怎么能行，相当于说比你买彩票还难，是要你去赌去猜谁买彩票会买中，是不是就更难？就是你赌这干嘛呢？你干嘛不稳稳的去找，我们说的叫做潮流产业的头部企业。所以我们讲在投资上讲的确性要比这个回报要更重要。因为你没有确定性的时候，你单讲回报率似乎很高。但是没有确定性的时候，那回报率再高，早晚也要输回去，而你有确定性的时候，回报再低，注意你别忘了原来很多人都提过的，这就是复利效应。复利效应的核心是什么？就是要求确定性，

就是每年赚那么多钱，虽然赚的少，但是每年一定能赚到，才能实现复利。如果十年里有八年是肯定赚很多，但有两年会巨亏，复利效应就没有了，对不对？所以大家一定理解，复利效应是对的，但是前提是求稳，不求高回报。所以你不要问我谁是百倍股，你要问的是谁是确定能赢的，所以这是我们的逻辑，希望大家能够在逻辑上跟我认同。

长鑫存储有没有确定性？长鑫存储的长期应用，就是产业的确定性是存在的。但是第一就是长鑫存储现在是不是高估了，我没判断，要去判断这个到底是不是高估，就是因为我后面会讲，没讲到长鑫，我后面会讲几个这个芯片公司，就是它收入未来也会涨，比如说寒武纪明显收入未来会涨的。但是问题你高估没高估和你现在估值有关，这是第一，大家要自己去计算一下长鑫的估值。我后面会用寒武纪之类的芯片公司的例子，可以你去看一看长鑫的估值是不是在那个范围内的这是第一。第二个就是长鑫，即使有确定性，也是这一波周期确定性。这一波周期能管几年呢？现在看起来至少五年对吧？但是更长了就不知道了，更长应该就不一定了，因为这五年都是因为这个内存会持续短缺。但是有前提是什么？尤其后两三年就更不确定。因为长鑫的内存毕竟不是高带宽缓存对吧？不是叫HBM，如果是高带宽缓存，它的确定性稳稳的能有五年。但如果不是高带宽缓存的，这个内存的确定性什么时候结束？有可能可能就是三年就结束了，这个小鸭子说的非常好，长鑫市盈率三百多，这个是个大问号，注意这个市盈率明显偏高对吧？我们说50倍市盈率是很合适的一个价位，就一个高速增长企业，五六十倍市盈率你基本上不眨眼，就是一个好公司。但是300倍市盈率这事儿就有问题了。然后中芯国际是确定性，中芯国际的确定性我认为甚至比长鑫存储还强。但是注意，主要指的是业务，主要是业务。为什么这么说？因为长鑫存储的确定性来自于它在内存界的地位，就是DRAM里面它是有价值的。但是第一，现在内存的最核心是高带宽缓存，而长鑫在这个领域里基本上没做什么。第二个就是我们讲在DRAM里面，它也没有那么独家。但是这个中芯国际，至少在这个就可以把它比喻成中国的台积电，所以它在这个芯片制造上，它的地位江湖地位还是要更高的。而芯片制造的需求，目前看起来就是至少比软件的周期，至少比内存的周期要长，所以应该是更安全，但是还是一样市盈率高不高，合不合适，这不知道。然后这个肖邦电感说长鑫如果对应今年的市盈率有可能会降的很低，今年它们的

业绩一定是暴涨的。对，如果是今年业绩暴涨，那也是看涨几倍，这个市盈率已经 300 了，也就意味着什么？意味着你今年的业绩比去年翻了十倍，你就降到 30，这就可以了，你就很厉害。但是一般业绩涨十倍很难，如果是涨三倍，其实还是 100 倍的市盈率的，所以不好涨。这不是收入涨三倍，市盈率是指利润涨三倍，你的市盈率还是 100，但是利润涨三倍也是挺厉害的。所以到底是怎么暴涨的，我们还要看一看。海力士依然空间很大，还是算了，我们就不讨论这事儿了好吗？大家一说这事儿，所以我前面说了那么多，你们又给我拉回来，我真是说实话有点失望。我们说了那么多，未来对世界的认知都变了，我们都要变成新物种了。你的特点就是，我就要在旧物种里变得更挣钱，那个旧物种里多挣那 0.12 元钱有屁用，真的，我说的不客气点对吧？我一般不说脏话的，大家不应该关注的更多是这些东西吗？关注的是市盈率那事儿，你真是让我哭笑不得，这谈着谈着就过去了，真重要吗？对不对？你看中谁是下一个腾讯，不比谁明天能多赚钱重要的多吗？谁是下一个 BAT，那不是更重要的事情吗？一定会出现，对不对？就只关注那明天那股票涨俩钱儿。好吧，回来就是 25 年的时候，我们做过 AI 生态的扫描，就说过美国芯片封锁让中国算力产业叫软硬分离。实际上中国灵活性更大，现在看来就是这样的对吧？中国的软硬就是分离的，这是因为我们没办法，硬件不提供给你，那硬件我们就七国八制，那我们软件也自己搞对吧？然后另外一个，26 年初、今年初的时候，我们讲国产芯片现在这在市场的窗口期，就是什么叫市场窗口期呢？就是这个推理芯片这个市场因为刚才讲了，就是训练芯片也是要实现替代的，但是能替代的人不多，但推理芯片能参与替代的公司挺多的，这有一个窗口机会，一旦你参与替代，成为替代的头部，你持续发展是没有问题的，是没有问题的。所以这个是我们讲过去基本上还是能够把今天看明白的，那今天的课就继续把这个细节给大家说清楚。




第一篇

需求爆发：国产AI算力基座

那一个就是我们还是看需求，今天说的是中国，就是中国的模型 Token 都在大爆发，中国和国外都在爆发需求都在爆发。当然国外也很好啊，国外涨的也很厉害。那主要国外涨的是 OpenRouter。OpenRouter 是国外的一个开放的一个平台。就是说你用了 OpenRouter 的服务，你可以随时切换大模型。那其中有大量的开源大模型。刚才推理芯片指的就是云端的推理芯片，不是端侧部署的，就是计算中心也需要大量的推理芯片。因为相当于说我们每个人问豆包问题的时候，他是用推理芯片来回答你的，不是用这个训练芯片来回答你的。就是云端的未来很有可能推理芯片和训练芯片在云端，当然这个是动态的，就很多推理芯片也可以调过来，很多训练芯片也可以调过来做推理的这是没问题。都是英伟达对吧？或者说都是华为，你能训练就能做推理，所以理论上是动态的。所以理论上讲最优结构的这个计算中心就是全都是能够既能训练又能推理。前提就是算力足够高。但是中国没有，就只有想办法说把高算力的放在训练上，把算力不够的放在推理上才会有这个市场。但是我们现在我们讲就是至少可行的，至少这样以前没有这么安排过。但是真正到了推理需求爆发的时候，发现说其实这么安排还是可以做到的，但是就意味着说我未来计算中心里如果采购不到大量的训练芯片，我未必全都采购英伟达，我采购一堆的推理芯片，只做推理任务这件事也可行，所以给了推理芯片一个发展的市场。这个市场很大，主要指的是云端的，不是指的终端的。所以第一个就是需求爆发，一方面就是中国的企业凭性价比切入了海外市场，包括比如说国外因为 AI 编程已经在年初的时候爆发了，对吧？尤其是这个 Agent

龙虾带来的编程的需求的爆发，这个 Token 需求的爆发。很多人用贵的用不起，就用中国的便宜的这 DeepSeek V4 Flash，它就便宜到 100 万的 Token 的输入是九分钱，百万 Token 的输出是一毛。那对应的就是国外最便宜的这种，因为它是经过蒸馏的小模型，这个国外最便宜的是 OpenAI GPT-5.4 nano。它的输入是两毛钱，但是输出是 1.5 块，输出比中国有六七倍，输入就是中国的一倍，当然这个如果别的更新的那就更贵。如果普通的这个国外的普通的模型，就是输入是一块钱，比中国就贵十倍。输出是 6 美元，比中国这个就贵不止十倍，几十倍，所以这个差距还是巨大的那当你需求量巨大的时候，你肯定省钱就很重要。所以中国的这个市场需求也在暴涨，中国的这个 Token 的需求也在暴涨，所以大家从海外赚到钱了。所以而且你看这对比就看出来，2026 年的一月份的时候，这个排名是这样一个是这个消耗 Token 的排名。到了 2026 年的这个六月份，你会看到说中国 DeepSeek 就上去了对吧？然后 OpenAI 就下来了，Anthropic 还是持平的。因为主要是这回的消耗 Token 的需求，主要是消耗的是 AI 编程的需求。所以你看 Google 也下去了，OpenAI 也下去了，但是 Anthropic 还是挺住了。而中国 DeepSeek 起来了。注意，这是 Token 消耗量。但是赚钱上而言，我们可能真没赚什么钱，为什么？因为您是开源模型，你要开源模型部署在自己这儿，用户到你这儿买 Token，还能给你交点钱。如果你开源模型被人家拿走了，比如 OpenRouter，就把中国的很多开源模型部署到他这个机房里。然后给第三方提供服务，你会给 OpenRouter 付钱。你给 OpenRouter 付的 Token 费和给 OpenAI 的 Token 费会混到一起，你就会觉得还挺合算的。因为其实这个说白了对 OpenRouter 而言，我给用户说的都是 Token。但是背后我知道我给你的如果是 OpenAI Token，我要跟 OpenAI 结算，我要给他好多钱的。但是如果给你是 DeepSeek Token，那我就只要在我的机房里跑着 DeepSeek 大模型，我就干赚了。所以就是说我用 DeepSeek 模型赚钱，但是我不分给 DeepSeek，所以就意味着说中国的在国外的 Token 的使用量剧增。但是中国在国外收入占比其实还是相对比较少的。

海内外中国模型迎来Token大爆发



中国AI市场份额大增

OpenRouter官方统计，2026年上半年DeepSeek 份额从约9%升至18%，6月初一度接近20%，中国模型已经长期在第三方排行中霸榜

中国AI性价比切入海外

DeepSeek V4 Flash最低端价约0.09/0.18美元/百万输入/输出Token，OpenAI GPT-5.4 Nano约0.2/1.5美元，最新的GPT-5.6 Luna为1/6美元

国内：Token需求的指数增长

4月，国家统计局透露3月份国内日均Token消耗量达到140万亿，较2025年底增长40%
字节透露，2026年3月豆包日均Token消耗量已突破120万亿，较2024年增长100倍，较2025年底翻倍，字节官方预期年底突破500万亿

当然长期来看是不是会比如说我们能够改变它的整个产业结构。这个我们今天没做论述，我们在讨论的时候讨论到了。但是我们还要再观察一段，没有特别清晰结论，暂时不要去跟大家讨论，原因就很简单，就是说取决于几个因素。一方面是未来一段时间这个大模型的水平差距到底有多大？是中国已经逐渐能贴近国外，还是说我跟国外始终有一定的差距。我们认为说后者的可能性更大。另外一方面就是说这个更难预测的。就是中国的这个开源模型如果使用量越来越大的时候，就刚才我们讲的，OpenRouter 收 5% 的费用。但是它对这个闭源模型可以这么收，但是在开源模型，尤其我们讲的 DeepSeek，那你就部署在自己平台上，那是最简单的。你搞一个云平台，你把 DeepSeek 部署在你这儿，那你除了交点电费，剩下的这个费用就都是你的了，所以就意味着说如果中国大量的去替代海外的话，就一定很多人愿意帮着来做这个替代。中间抽成赚钱。所以 OpenRouter 也是五月份刚融了一亿美金，估值 11 个多亿美金，也独角兽了，他实际上就做的这个流量中介的生意。那中介肯定更多的不是为了中介 OpenAI，人家可以直接找 OpenAI，肯定是中介这些第三方的中国模型。那另一个问题就来了，如果第三方中国公司都是用开源的名义，这个费用也特别低，对吧？那么就带来一个问题，就是会不会美国政府又继续要求，就跟之前已经要求了，但是没有特别强的强制执行。但未来会不会变成一个强制执行，就是要求美国不允许，就是现在是不允许中国人用美国人的好模型，但是反过来是不是不允许中国模型给美国提供支持。

所以这个有它的政治味道这个就要稍微观察一下，至少这之前反正
【课程入口】公众号“全球风口”进入特训营

Anthropic 公司就特别拧。他们就前阵子专门跳出来了，针对中国去说中国人工智能怎么样，中国蒸馏它了，怎么样，就是中国蒸馏它没有，现在看起来应该是蒸馏他了，但是这应该是个惯常做法，就是因为实际上也有明确的证据，Anthropic 也蒸馏过中国的模型，这是非常明确的证据的。所以这时候如果你只说你偷我的，不说我偷你的，这件事似乎似乎有问题。要么你就说这不叫偷，要么就是说我偷你，你偷我的我也承认我也偷了你的了，而不能不承认他自己的事儿，只说别人偷了我的，这个站在道德制高点上谴责别人。记不记得我之前说的 Anthropic 具备这种欧洲的技术，精英主义的傲慢。就是自己做的事儿都不是错，但是在自己眼里，别人做的事儿就经常能够被自己指责说他可以指点，就是说你看你这事做错，你这事做错了，但是谁有资格指点江山呢？谁有资格去判断别人做错了呢？对不对？所以未来应该是分布式的 distributed，分布式认知没有一个人有资格，但是整个社会是有资格的对，因为如果没有资格，这社会就乱了，谁都没资格，这社会就乱了。一定是没有一个人有资格，但是这社会有资格。但是这社会如何形成？这个分布式的认知如何形成？这就很关键，就要有一套机制来保障吧？他不是过去你最起码还要是叫民愤极大，或者族长召开家族会议作为一个机制。但是机制不够好，未来人工智能来了以后，如何能形成更好的机制，这都是我觉得是特别有意思的话题。说远了，简单说就是中国模型迎来了大爆发，这个不光是国外因为便宜，也因为国内自己本身也爆发也涨得很厉害。所以这是我们最高兴的看到的，中国本身也做到了也做到了爆发。

国内 Token 需求结构：推理爆发中的算力分层



好，这个国内的 Token 的需求结构，我们说一个是这个需求作用在什么地

[【课程入口】公众号“全球风口”进入特训营](#)

方？用在广告，用在叫大众助手，就是大家日常的 APP 提问，那现在迄今是最高的，但是这块没啥收入，因为你就是靠收月费，中国人不习惯交月费。然后第三个是 coding，然后多模态和这个叫政企。注意看什么叫做算力战，就是谁消耗了更多算力。当然一个就是前面这没有的一项，就是训练本身消耗了 24% 的算力，就是那个算力不能只分配到这个，因为这后面这些都是推理，这所谓的应用就都是推理了。但是训练的算力需求是现在算力占比 24%。另一个就是这个广告、搜索，它的收益占比。注意它这个区别在哪儿，它的算力占比是 20%，但收益占比特别高，为什么呢？就是立刻能见着钱，立刻能赚点钱。这当然这个赚钱指的什么？指的是大公司自己赚钱。也就是说我是 Facebook 或者我是字节，或者我是腾讯，我通过广告、搜索、推荐能够赚好多钱。这种时候，当然他就愿意投入，这是我们这说白了这条就挑明了说大公司为什么愿意自己做大模型？因为我自己的大模型，我自用都有很大的需求。

然后另外一个就是大众助手，你看算力占比很高 14%，但是收益占比只有 8% 点几，说明什么？就赚不着钱，但是下一个这个 coding 就是这个编程，就是它的算力占比 22%，收益占比 23%，这个是赚着钱的领域，赚得到钱的领域。还有另一个领域是多模态，就是说虽然它在国内的市场显得很小，但实际上它的算力需求，它的算力消耗挺大的，算力占比 13%，比这个市场要大很多，另外一方面它也能赚上钱，它的收益占比也能 13%。所以这两个注意这两个就是 Agent 和这个多模态是当然也吃算力，但是能够赚回回报的，而且未来的增长也很好的，两个领域值得关注。然后另一个客观理解，表面看政企客户，尤其 AI for Science 客户，也占了 7% 的算力，同时也带来 9% 的收入。但是这个收入不确定，因为政企的收入它没有连贯性，它有偶发性突发性。近期很热大家就投了，明天如果不热就没有了，所以要观察政企是不是能够常年持续发展，这是一个大问号，包括现在这段是不是有可能是一次性的高投入。因为去年很多是卖一体机，卖所谓叫 AI 方案到大公司的，它是一次性的。然后它不是云端服务，它是直接软硬件给你了。你赚一笔钱行，赚长期钱就未必行，所以我们看起来就这个需求里边，主要是三个值得关注的。一个是公司内部普遍有自己的需求，这是他投入大模型做大模型的动力。另外一个市场的最好的两部分，一个就是 coding，一个就是多模态。确实需要有算力做支持，没有算力做不到，但是也给你带来很好的回报，

这是中国，所以总的来说我们认为还是很理性的一个市场。这个 coding 和 Agent 在引领需求爆发，现在还不是大头现在还不是大头，但是因为它规模还比较小，但是它未来会很大。当然这个已经有一堆人惦记了，就是国内大厂发布的这种各种 AI 编程工具，你看基本上都参与了阿里巴巴、字节、腾讯、百度，华为、这个小红书、京东都参与了对吧？所以基本上都是人人都参与。但是坦白讲这个还和刚才说的自己公司内部的那个叫大模型不一样。因为我如果是处理我公司的内部的广告，宣传，算法优化，那我最好是用自己大模型，但是如果是我用编程工具，那理论上讲，当然了我也希望是自己编程。因为好像已经有人国内已经有人说了，禁止使用像国外的编程工具。但是我们说了编程是一个最基础的事，那理论上还是谁家好用谁啊。所以应该会有很多 IT 公司，虽然我的大模型不是最好的，但是我为了自己需求我也还会去用。但是理论上编程不应该，因为编程是生产工具的工具，应该用最好的。所以就是说国内人人都做编程工具这件事应该不靠谱。未来有很多也不用做，做不了。

科技特训营

Coding/Agent：引领需求爆发，但还不是大头



当然具体的市场是多少呢？我大致的给大家做个估算，我们不详细展开说了。大家可以这么去看，我们用三种方法，一个叫用户法，一个叫 Token 等价法。用户法就是算有多少用户，因为中国 GitHub 用户规模是 1000 万，然后我们按月费和转化率大概市场规模有多大。还有一个叫 Token 等价法，这个是日均 140 万亿的 Token，这是政府公布的数据。按这个数据来算，coding 占其中的多少，然后值多少钱，市场规模多大也能大致算出来。还有一个就是厂商收入反推，就是智谱 2025 年。因为很多公司他没上市拿不着，但是智谱上市，所以 2025 年 API

【课程入口】公众号“全球风口”进入特训营

收入是知道的是 1.94 亿元，其中的 coding 占中国市场 5%到 30%这个比例来计算，大致也能知道中国市场。最后总结下来，就是我们认为中国市场大约是一个 2 到 25 亿的这个明确范围，基本上认为大概在落在 8 亿左右，这个市场是比较现实的一个评估，也就是中国的这个 coding 的市场，就是现在还不大，几个亿。但是它在快速长大，这个是值得我们关注的一个市场。

前瞻科技特训营

广告、推荐、搜索：互联网大厂内部的AI创收路径

生成式推荐和智能出价推动国内广告收入约3%—4%；
OneSearch V2 AI推荐系统推动电商搜索GMV约3%

快手 2026 Q1官方披露

今年会把有限的GPU优先用于混元模型的开发，微信Agent、元宝，广告和游戏AI以及WorkBuddy/CodeBuddy
更多腾讯云容量等待国产GPU在下半年增加

腾讯 2026 Q1 官方披露

全栈AI投入已从孵化阶段进入规模商业化；外部云收入增长40%，模型、基础设施、办公/Coding Agent和电商生态整体推进中

阿里 2026 Q1 官方披露

然后基本上，对大厂而言，互联网大厂而言，就是广告推荐和搜索，这是大厂里面最能够做成的事儿。就是一个是快手智能推荐和智能出价，推动它的国内广告收入提升了约 3%到 4%。这个推荐系统这个怎么怎么样，这个不详细说了。另外也是腾讯也在说类似的事儿，就是它自己内部用于它的微信 Agent，用于广告游戏等等，当然腾讯有一个叫 CodeBuddy，这个 CodeBuddy 就是它希望做中国的 Claude Code，就跟刚才一样，就是都在想做中国的编程这块。但是到最后谁会赢还是不知道，还要看一看。阿里 2026 Q1 的时候说，AI 全栈投入已经从孵化阶段进入规模化阶段，然后外部营收增长 40%。发现没有？他强调模型基础设施办公、coding 和电商生态整体推进中。为什么整体推进中？因为它就和腾讯、和快手比，和字节比，它不自带流量。就是这个阿里的淘宝流量很多还要买流量把用户导过来，但是他自己的内生流量不够大。如果内生流量不够大的时候，你用来做广告做什么，就优化的效果就没那么好。所以在这几家公司里，阿里的 AI 创收相对来说还是要弱一点，要靠这些东西的综合。

然后李 LH 说：王老师 AI 多模态的应用，诸如中文在线现在仍然处于亏损，而且很难铺开订阅制。未来如何盈利？全球化，而且这个中文在线是什么？AI 多

【课程入口】公众号“全球风口”进入特训营

模态？中文在线不是小说，小说阅读，怎么叫 AI 多模态了？是说他做这个 AI 短剧，如果 AI 短剧未来是有机遇的，那现在处于亏损，但是未来是有机遇的。当然有机遇也是一样，就是说两种，就是在中国做订阅制确实碰了一个先天障碍，就是太多免费的了，你想收费别人不收。但是第一你到海外做订阅制，第二如果你流量大也行，比如说中国确实比如说看短剧都是用红果短剧，那他也不收费，但是你流量大有插广告。比如我自己就是红果短剧的重度用户，经常用短剧给自己洗脑，但它本身就不收费，不是我不想交费，但是它广告经常命中我。因为他这个很精准，所以我给他奉献的广告给他带来的收入绝对比订阅还要高，所以只要有流量，这个很重要的，这也是另一个我们整个话题要讲的是到最后中国真正的机会是在应用，越往应用推越有机会。就是你像这个属于叫红果短剧这样的 AI 短剧，国外叫 ReelShort 这种事儿，这咱中国人来干，擅长干，大公司不擅长，中国大公司还好，美国大公司更不擅长。所以这就是机会，就是机会一定往应用侧推。就跟打仗一样，最开始一定有基础侧的机会，但是大多数人喜欢留守基础设施机会，尤其是大家说留恋过去，技术侧机会已经有很多公司实现了百倍暴涨了。然后你还在那看说下一个百倍暴涨在技术上还有什么？它会迁移了，不是在技术侧了，在应用侧了。就是一层一层往下走，当然我们说另一个就会有扩散，就是一个是前移，一个是扩散，前移往下走，扩散就是说我基础设施的一个核心，英伟达百倍暴涨了以后，现在就是这个叫高带宽缓存百倍暴涨了。然后下一个会不会其中的某个，就像比如光模块某个也会有暴涨的机会？肯定有，比如我们之前曾经介绍过，国内有一个做铰链的公司，因为铰链做的特别好，所以它利润特别高的一部分就是给这个叫计算中心的机柜做铰链，这个公司万一某一天被炒作，它也会暴涨的。尤其是小盘股被炒作特别容易暴涨。你看这个是有多好的题材，我是给这个英伟达独家提供铰链的，而且利润特别高。对，为什么利润特别高？因为英伟达在它那个成本里面，你这是特别小的一块，它犯不上跟你去讨价还价，那 0.12 元钱还是没看上。对，但是问题是您觉得这是捡着的钱，在英伟达产业链里，你什么生态地位都没有，什么话语权都没有，对吧？所以就没有意义，就没有意义。所以我不看啊，就是我知道一定会有这样机会，但是第一他在哪儿，第二什么时候出现，都要花很大的功夫，要不然你就是买彩票。所以我不买彩票，我也不会做这样的操作，我会宁肯放弃这样的机会，我知道一定会有，但是我会

放弃这样机会，也不去探索这样的机会没有意义，人生很短，不值得浪费。

然后嘉琛说：中文在线参股 ReelShort。以前我们其实介绍过中文在线，以前是控股 ReelShort。后来是 2025 年大概秋季 9、10 月份做了股改。然后中文在线的股比已经占到了 50 以下，已经不到 50%。不控股了。那不控股的意思就是想上市，所以如果上市的话，我认为是挺好的，当然还是一样，我们没有在讨论投资或者是讨论业务。然后明天说：王老师昆仑万维只做海外 100 个国家布局，有自己天工大模型短剧流量目前 number one，日均 4 亿核心用户，国内唯一布局。我反正昆仑万维小心点，这个公司挺神奇的，神奇的公司都要长期多看一看再做判断。但是我反正对神奇公司都不是特别看重，因为有可能碰到了神仙公司，但是多数是妖怪公司，就跟说像 Dreame 似的，偶尔看一眼，但是不会认真，特别认真看，像 Dreame 似的。也是一样，这个万兴科技做视频有什么牛的？反过来讲，从我的角度去看什么公司可能好。但是你提了一个公司，我再给你提一个领域，但是我为什么提这个领域不提到，你说这个公司。如果这个公司真的好，应该被我关注到，好吗？所以一定是反过来思考，要不然你给我一堆小公司，对每个垃圾公司都做分析。但是不是说小公司有垃圾，也有点说的大了，然后对每个公司做分析，我们就耽误大事儿了，我认为还是这样。我们说过了，大革命是不看小山头，我们看着下一个巨头，你要先说出来它能成为巨头的理由？所以一样的，潮流头部，一定要养成。所以大家发现没有我其实更多的时间在给大家扳你的思维习惯。因为我们大多数人真的就这种思维习惯，就是天天就往回拽，我再给你往上拽，你得往回挣扎，以后回去我就要想着明天哪个公司赚钱，我就想这个 PE 是多少，是不是？所以为什么我连炒股都不炒股，炒股真的会干扰你的长期思维，因为你想要的就是明天赚不赚钱，但是哪个公司他的长期业绩是由明天赚不赚钱决定的，所以一定要明白我们自己这个时代，要知道自己认知的局限。

多模态与出海：收入增长快，但只有部分回流

中国模型/应用海外收入
十亿美元



基于已公开上市企业估算，不包含独立出海/应用创业企业


综合可灵、MiniMax上市企业公布的数据，参照DeepSeek、Kimi公布的Token规模和海外占比，预计2026年中国AI企业出海收入在8-15亿美元规模，2029年在AI模型能力保持当前格局，算力价格不变的情况下，预计会增长到120-240亿美元

中国模型打入国际市场，但开源限制创收

海外客户可通过AWS/海外GPU云调用中国模型，收入并不全部回流

然后多模态和出海？这个收入增长很快，这个是有机会的。但是只有部分回流，什么叫部分回流呢？就很多人被人拿走了，因为刚才说的像这个 OpenRouter，我把你的大模型在国外架起来，我就可以拿走了。但是中国如果主动出去，我觉得可以钱赚到自己手里，就一定要学会钱赚到自己手里，所以中国要尽快出海，尽快在海外建立自己形象，然后让用户直接和自己产生关联，钱才能赚到自己手里。要不然你本来就开源，你比如说像 DeepSeek 也是一样，开源就两种，你用了以后，任何第三方都可以在海外，在自己的 server 上服务器上建立架设 DeepSeek。那别人某人用 DeepSeek，其实是开源别人的服务器上架设的 DeepSeek，那钱就被人赚走了。但是如果说中国的 DeepSeek 推到海外去了，或者说通过你的官方 API 引入的用户，或者是官方的 APP 用户进来的，那这种时候那就是你赚钱，所以说中国的市场已经打开了，下一步就是谁能把市场里的钱赚到自己手里，尽量让它多数回流到自己兜里，而不是回流到别人兜里，而不是回流到第三方兜里了。但是这个很重要在哪儿？就是它市场实在太大了。我们的预测，2026 年大概只有 10 亿美元左右，2026 年预计中国 AI 企业出海，整个的中国 AI 企业出海的收入在 8 到 15 亿美元的规模。但是到了 29 年的时候，我们就会预期涨到 120 到 240 亿美元。你看看是一个倍数级的增长，这是非常重要。

结论：需求暴涨与结构变化同时发生



悦行远方说的就是大模型公司也要在海外建立自己的品牌。是的，我就这个意思很直接，而且如果他很聪明地建立品牌，他能大胜。如果不是很聪明地建立海外品牌，他可能会死掉，这是一个生死的抉择，结论就是国内的这个大模型这块儿，尤其是这个 Token 需求这块，市场需求这块是需求暴涨和结构变化同时发生一个趋势。一个需求在暴涨，另一个叫结构变化，什么意思呢？就是说未来你看得见训练的比例，因为整个暴涨了以后，训练也在涨，但是训练在整体的比例在下降。然后还有一个下降的是什么？就是广告也在下降，但是广告应该有实质性的比例，为什么呢？因为这是人家大厂用来继续赚更多的钱的，就是说我们把它叫技术封建主义。所以我特别喜欢谈理念，因为说实话你要知道这理念说的什么，它就成为你产业分析的指导，就能让你分析出很多东西来。但是我特别有时候跟人谈，有时候觉得很郁闷，就是我就把这个理念说到就成一层窗户纸了。对方依然问我说你没讲任何实际的东西，相当于说我告诉你 1 加 1 等于 2 了，你让我推荐 1 加 2 等于 3，然后你告诉我说你没告诉我怎么能推出 1 加 2 等于 3 来，我就比较无奈的，所以这个特别重要，理念对我来说是最重要的东西，是你的思维工具。思维工具强化了以后，你什么东西自己就分析出来了，那是属于你的不更好。所以这是一个广告是在下降，但是不会死。然后大众助手是明显下降的，因为它不赚钱，不是没需求，是不赚钱。但是后面两个是明显增长的，一个就是 coding 编程，然后另一个就是说的多模态，这两个是会明显增长，这是比较值得我们关注的。



第二篇

万卡工程：国产芯片技术进展

另外一个就是看芯片，我们说看了需求了，然后再看芯片层。芯片层这个大家我们就讲未来一定是万卡，万卡的核心是什么？不是说非得是形成万卡的集群，而是你有没有万卡的能力，你没有的话就是你没有足够量产化的能力，没有足够的规模效应，你就可能就死了。当然这未来两年就是看谁能够上量。

AI算力已经是系统工程，训练与推理架构相似问题不同

英伟达官方GB200服务器组件

NVIDIA DGX SuperPOD：面向 AI 领导力的下一代可扩展基础设施参考架构
采用 NVIDIA DGX GB200，最新发布

表 3.1：NVIDIA DGX SuperPOD 硬件组件

组件	技术	描述
8 个计算机架	NVIDIA DGX GB200 NVL72	全球首款机架，专为 AI 打造。采用 NVIDIA Grace-Blackwell GB200 模组，GB200 模组芯片，NVL72 模组扩展的 GPU 互连和集成 NVLink 交换机芯片。
NVLink 网络结构	NVIDIA NVLink 5	NVLink 交换机支持在同一计算机架中 GPU 之间进行快速、直接的内存访问。
计算网络结构	NVIDIA Quantum CM7700 InfiniBand 交换机	针对超高性能、非阻塞、全互联网络，每个系统配置八个 800Gbps 连接，用于机架 GPU 通信。
存储和内存管理网络结构	NVIDIA Spectrum-4 SMI6000 以太网交换机	该网络结构针对配置存储阵列的峰值性能进行了优化，采用 64 端口 800 Gbps 以太网交换机，提供高端口密度和高性能。
InfiniBand 管理	NVIDIA 统一网络结构管理设备（企业版）	NVIDIA UFM 将强大的实时网络遥测与由 AI 驱动的网络智能和分析相结合，以管理大规模 InfiniBand 数据中心。
NVLink 管理	NVIDIA 网络管理 器 eXperience (NMX)	NVIDIA NMX 管理和程序 NVLink 交换机，并提供实时网络遥测功能，以管理所有 NVLink 基础设施。
带外 (OOB) 管理网络	NVIDIA SMI2017 交换机	48 x 1 Gbps 以太网交换机，用于网络端口管理。

AI 进入算力工厂时代，竞争单位从单卡变成系统

GB200 SuperPOD并不是简单堆叠GPU。一套可运营的AI算力同时包括计算节点、NVLink 互联、InfiniBand网络、存储网络、通信库、集群管理和故障恢复。单卡峰值算力只是理论上限；模型最终获得多少有效算力，取决于整套系统最薄弱的一环。AI芯片竞争已经从“谁的单卡更快”，转向“谁能稳定、低成本地生产Token”。

它（CUDA）现在之所以好用，是因为投入的人多，好多人写算子、优化，你用的时候，人家都给你准备好了...现在CUDA更多的是批量优势、投入优势，不是一个技术点本身的优势

当然，CUDA的通信库这个东西还是比较核心的.....英伟达的通信库做得要比我们国产厂商的通信库更加完善一些

——受访计算机相关AI硬件专家


那一个就是我们说 AI 算力已经是个系统工程了，首先说之前讲过算力训练和推理的架构是相似的，但是解决的问题是不一样的，它关注的重点也不一样。那就造成什么呢？可以用同一个芯片，虽然理论上讲的就是训练芯片的要求的算力更高，所以推理芯片不一定能用到这个训练上。但是训练芯片一定能用到推理上。但是在系统工程的层面就不太一样，做训练的时候一定是个大系统，就一定要强调万卡。但是做推理的时候，就可以是好多好多的小系统也没问题。表面看

【课程入口】公众号“全球风口”进入特训营

我们就说好像是七国八制各国都进得去，因为可以小系统，但实际上一样，我为什么要呢？虽然是不增加多大的难度就可以把别人的这个推理芯片集成进来，但是就那点难度，我为什么要增加呢？如果我是一个商业机构的话，如果是国家任务，当然就必须增加难度了，但是如果是商业行为的话，为什么要增加？为什么不直接采购现有的呢？而我们说未来一段时间商业行为会主导，国家任务会不主导，因为国家任务没需求，所以需求还在，这个我们说叫一体机阶段。而且我们这回不是也讲了这个，就很多时候的需求的满足，为什么国外能做到人工智能在企业应用上都开始大量的被采用。因为它这之前实现了企业的数字化，后来又实现了企业的网络化，就是大量的企业本身它的这个服务器，它的整个系统都已经架设在网络端了。它早就用云用了十年了。它现在成功的在云上直接加人工智能，它是很顺畅的。而我们你想，现在还在做一体机，一体机是啥东西？所以这个就是没有基础它不可能，罗马不是一步建成的，这就花时间的。所以我们应该说现在国有的包括大企业主导的 AI，依然还是和民间的 AI 或者说和每个用户自己用 AI 来做点程序什么优化一点流程没多大区别。

科技特训营

训练与推理分离：Token生态变化背后的工程差异



模型训练：大量芯片同步并发，通信/协同成为重点

华为研究，通过把 Transformer 训练中的计算任务拆细，并让通信与计算更充分重叠，可以显著减少 GPU 等待时间，提高训练效率，能将训练中的关键指标模型浮点运算利用率 (MFU) 提高9个百分点

默认方案是“通信完再计算”，华为的MC2则通过切分、流水化和Kernel融合，让通信藏在计算背后，从而缩短单步训练时间，提高GPU利用率。

- Comp.: 计算任务
- Comm.: GPU 之间的通信任务
- ATTN: Attention, 注意力计算
- MLP: 前馈神经网络计算
- AG: All-Gather, 把分数在不同 GPU 上的数据聚合起来
- RS: Reduce-Scatter, 对各 GPU 的计算结果求和或聚合后，再分发回去




Figure 1: RTP-LLM System Architecture

模型推理：并发请求与算力资源调度是关键

阿里论文分享面向1亿用户，不同参数模型的推理调度架构

RTP-LLM 推理系统，把请求调度、Prefill、Decode 和 KV

Cache 分层管理，并在集群中解耦

RTP-LLM 将大模型推理拆成“统一请求调度—Prefill 计算—

Decode 生成—多级 KV Cache 管理”四层，通过 Prefill/Decode

解耦和四级缓存体系，缓解 GPU 显存瓶颈，提高大规模并发

推理吞吐量与资源利用率

所以注意它还不是一个系统级的 AI 的提升，所以还比较早。这个训练和推理分离我就不详细展开讲了。简单说就是模型训练的时候，大量芯片要同步并发。一个就是要万卡级别，算力越强越好。第二个就是要通信和协同成为重点。大家记不记得我之前就一直在强调，中国为什么华为能和英伟达竞争？因为华为是个通信公司，华为对通信理解比英伟达还强，而这件事他说白了就是大规模的企业计算，就是大规模的计算。那么多个 GPU 在一起，它需要的通讯调度能力甚

至比单芯片的算力还重要。而这个通讯能力怎么解决呢？它不是个什么技术的问题。我们这两天专门采访了国内的这领域的顶尖专家。不说是谁，人家要求不能公开人家姓名，但我们采访的领域顶尖技术专家，基本上也是验证了我们的判断。就是说这个核心实际上是这个通讯能力的需求，是特别强的那当然华为在这上面就会有优势。而模型推理就是另外一个事儿了，就是它实际上是一个叫算力资源调度，甚至是资源管理。因为它是大量的并发请求，就是大量请求其实都是很小的事儿，就是要不了几片芯片，一跑就出来了。那不需要这个万卡一起来计算，所以它可以很小。但是它的量大，就是它的需求量大，每个需求解决都是很简单的事儿，所以这样的话，也要足够多的卡，但不是需要万卡集成到一起。但是我们也讲过了，这是只是从技术上不要求所有的卡都一样，可是从商业上讲就是另一个故事了。所以大家知道训练和推理现在已经分离了，这个背后的技术也是明显开始有越来越多的差异。一个强调的是通信和协同，另一个强调的是算力资源调度，国内在做什么？国内做的事情，主要第一个训练上有初步突破，这个我们收集了，后面还会有更多的列表收集一些例子。一个报道就是美团在 5 万卡国产集群上训练出一个 LongCat 2.0 的模型。你看美团自己也搞自己的模型。为什么？我们说了，只要你有用户、有流量，你自己用自己的模型就省钱，就可以赚钱，这美团训练这个 1.6T 的参数，T 是万亿，这未来这个大模型的参数都是 T 级的了，然后 100 万上下文，现在这基本上这些参数都变成标配了，就说明它这个模型并不太落后，也就是基本上是一线模型了。那根据他公布的论文看，我们看，就是因为他不公布是用的谁家的国产这个芯片，它只说是国产集群，国产芯片做的集群。我们分析一下结果，应该是华为的这个 910C，因为别人家没这水平，这是训练。推理上，主要是要解决一个叫百卡集群上高效推理落地的一个落地方案的问题。所以华为推出了 CloudMatrix 架构，阿里是用 RTP-LLM 在它的这个大模型推理框架 RTP-LLM，在软件层面也是推理集群资源调度。实现这也是一个规模了，实现服务超 1 亿用户、超 1 亿人的并发。这个能够被及时响应。但是核心的就是说都是如何能够叫并行多路并行，这个多路并进如何去能够解决高密度、高速、高效的问题，这部分就是中国我相信很快会有很多的实践出来。但是这个实践你看什么都是往大厂在做，因为它还有那么多的需求，别人没那么大需求，因为你首先你这个模型天天被人访问，才有那么大的量，所以这是推理，

推理的核心说白了就是要解决现有的这个推理需求暴涨，如何还能够支持得住的问题。也在模型上希望通过模型的优化解决训练和推理问题。

科技特训营

国产算力三层突破，成熟度不一



LongCat-2.0
OPEN SOURCE

1.6T PARAMETERS ~48B ACTIVE 1M CONTEXT



CloudMatrix 384 超节点

高密 高速 高效



Deepseek V4 Coming

Coding Breakthrough Business Competition V3.2 Full Release

国产训练：初次  **提取文字** **更多**

美团在5万卡国产集群上训练出LongCat-2.0模型，1.6T参数、100万上下文的多专家模型，根据美团公布的论文看该算力集群预计为华为910C

生产推理：多路并进站在关键点

华为CloudMatrix架构提供了百卡集群上高效推理的落地方案，阿里RTP-LLM则在软件层面演示推理集群资源调度，实现服务超1亿用户的方案

AI模型：工程优化取得一定进展

DeepSeek通过在MoE（多专家模型）、MLA（工作记忆）、FP8（低精度）与训练中数据流水的优化，极大提升模型训练效率，降低模型算力成本

现在主要一个重点，这一两年中国就还能够再进一步，因为现在慢慢大家都在做，所以叫 FP8，这个我们之前应该解释过，对应的 FP16，就是说等于小数点后多少位，小数点后多少位呢？这个表面看是精度降低了，不需要算到后 16 位，8 位就够。但实际上这个其实计算的就是因为人工智能强调是推理，它不是完全的数学计算，就是这种推理的结果。实际上 FP8 低精度的这个数学的东西的推理结果反而会更好。所以现在中国也都会普遍换成 FP8，已经开始在做这方面工作，未来一定是属于 FP8 的，就是意味着我们的人工智能的水平有进一步提升。而 FP8 好的地方就在于说它在模型训练上也有一定优势。它会提升模型训练的效率，而且降低这个模型算力成本。所以它对训练有用，所以我们一方面我们是芯片要顶得上，然后要这个模型要去跟它适配。另一方面模型本身也有优化空间，但是还是一样，因为最大的卡点，注意最大卡点其实还是在硬件本身，就是在芯片和这个产业集群上。因为它必须要万卡集群，所以这方面基本上没有人能和华为竞争，这个起码还是要靠华为，那对于推理，就是很多家都可以做，尤其是大家都有需求，需求方就可以锻炼。

近一年国产算力训练/推理关键进展

时间	企业/案例	训练/推理	简介	突破点
2025/4	华为 Pangu Ultra	大规模预训练	在8192张昇腾NPU上完成1350亿参数Dense模型、13.2万亿Token训练，并通过训练稳定性与系统优化提高芯片有效利用率。	国产芯片、训练框架、网络和集群软件已经能够协同完成百亿至千亿参数稠密模型的完整预训练，而不仅是推理或微调。
2025/6	华为 CloudMatrix384	超节点推理	把384颗昇腾芯片与CPU、高速互联组合成统一计算系统，并支持Prefill/Decode分离、专家并行和分布式KV Cache。	推理性能不自由单芯片决定。高速互联和系统调度可以把大量芯片组织成一台“更大的计算机”，放大整体吞吐。
2025/7	智谱 GLM-Image	国产全流程训练	数据处理、模型预训练和工程运行使用昇腾Atlas800T A2与MindSpore体系完成，关键训练环节不依赖海外GPU软件栈。	国产芯片和软件体系已经能够覆盖多模态模型从数据准备到训练完成的全流程，而不仅是部署现成模型。
2026/2	智谱 GLM-5	Agent工程+国产适配	采用稀疏注意力降低上下文成本，并用异步强化学习基础设施训练长程Agent；模型从训练初期就考虑国产芯片适配，覆盖多种国产平台。	模型架构、强化学习系统和国产芯片部署开始协同设计，而不是模型训练完成后再做被动硬件适配。GLM-5论文明确采用DSA、异步Agent RL，完成多种国产芯片全栈优化。
2026/5	智谱 ZCube	千卡级生产推理网络	在GLM-5.1 Coding生产集群中，把传统多层网络改为更扁平的GPU互联结构。GPU、软件栈和应用不变时，交换机与光模块支出下降33%，平均推理吞吐提升15%。	推理瓶颈已经从“GPU不够快”扩展到网络是否拥堵。即使不增加一张GPU，只改网络拓扑，也能让同样的算力完成更多请求。这是工程部署成果，不是模型论文。
2026/5	阿里 RTP-LLM	工业级推理引擎	将模型加载、Prefill/Decode分离、多级KV Cache、推测解码、量化和多模态推理整合进同一引擎，服务阿里内部超过1亿用户。论文报告模型加载提速4.7-6.3倍，生产流量下P95首Token延迟下降35-37%，缓存复用率提升2.15%。	大模型推理优化不是单一算力加速，而是模型加载、缓存、网络、调度和生成算法的全系统协同。
2026/6	美团 LongCat-2.0	国产五万卡训练+推理	在约5万张国产AI加速卡组成的集群上完成万亿参数模型训练和推理，并处理大规模集群调度、通信、容错和稳定性问题。	国产算力已经从“单卡能运行模型”发展到“数万卡可以完成前沿模型工程”，竞争重点转向集群与系统能力。
2026/6	智谱 GLM-5.2	百万上下文+长程Agent	支持100万Token上下文；IndexShare让每四层稀疏注意力共享一个索引，在百万上下文下控制计算增长；发布首日完成九美国产算力平台适配。	模型开始真正面向持续数小时、包含大量文件和工具调用的长程任务。它证明长上下文、生成速度、工程稳定性和国产部署必须一起设计，而不能只追求模型榜单分数。

我们把近一年国产算力和需求、国产算力和推理的一些关键进展把它列出来。我稍微多说一句，其实核心我们是按时间列。你看最近这个进展还是蛮多的，但是注意这个训练的进展不多。一个是华为昇腾在 8192 张昇腾芯片上，完成了这个 1350 亿参数的一个模型的一个训练，注意这是训练。还有一个是智谱的 GLM，那个 GLM-5.2 最近的效果不错，也蛮受关注的，那 GLM 也是全流程的训练。注意我看到的时候，他用的也是这个昇腾叫 Atlas 800T，Atlas 800T 实际上是用的是华为的芯片来做的这个集群，就是它的这个 Atlas 是它的集群的名字，这后面还是华为芯片。然后美团 LongCat 刚才说了，5 万卡级别的训练，这个是迄今为止国内做的公开的规模最大的用国产芯片来做训练的这样的案例。那他没说谁的，我分析的也是华为。你看这三个红的是训练，其他都是推理的，所以这三个可能都是华为对吧？所以还是对应着我们的这个判断，就是国内能够在训练领域扛打的就是华为，别人都不太行，所以大家都别吹牛，所以我们一直想要万卡，万卡就是这个概念就要分清楚，就两个意义。一个意义是技术上的意义。这个意义就是万卡集群真正在训练上是有用，在推理上没什么用。万卡决定上限，就是说你如果真的是这个推理需求特别大，那我当然卡越多，我能够满足的需求越多。但是实际上要完成某个推理，完成一个推理，10 卡到 100 卡就够了，就不需要万卡。刚才说了 GLM-5.2 不是华为训练的，GLM-5.2 是现成的，正在做这个训练。然后推理，所以不一定非得万卡，只是我如果推理量特别大我当然需要卡多了。

"万卡集群": 概念炒作背后的三层含义

训练：万卡集群真正价值所在

随着模型参数不断提升，训练对协同计算的要求持续提高，需要超大规模的算力集群提供协同计算，是万卡集群真正的需求点

推理：万卡只决定上限


单一推理任务10-100块以内的小算力集群足以应对，万卡集群更多决定AI服务器容量的上限，对资源调度有一定优化，对单一任务优化有限

供货：大多数万卡概念的本质

大多数企业的万卡集群概念只是说明拥有了提供万卡的能力，与能否完成规模训练，规模化的推理服务没有直接关系

关键问题在这，关键是在商业上供货，供货需要所谓万卡集群概念，说明有提供万卡的能力。它不是说你能不能完成训练，能不能完成推理，但是他是说你的供应力，这个在商业上非常非常重要。然后另外就是我们讲过了，他表面上确实不需要万卡，确实百卡都能行，100个百卡也这也可以混成一个推理的一个集群。但是问题它还是有难度的，不是完全没有的。而我们强调在商业上，你肯定没有必要去给自己增加难度。干嘛？如果你有政治需求，那必须得做对吧？不是政治需求，纯商业没有必要增加难度。

异构集群：多芯片组合存在，但任意混算难长期维系



1000块不同厂商的GPU异构计算研究，需要独立调度策略解决不同芯片带宽、存储、通信不统一的问题
黑圈为芯片处在迭代进步曲线的异构场景，红圈为更广泛的不同芯片异构场景


难度	算力异构状态	成熟度
L1	多个独立同构池	模型/云平台应用中
L2	同一模型适配不同芯片	模型厂商适配主流国产芯片，其他适配由芯片厂商完成
L3	不同厂商共同运行	研究阶段，最高千卡级别

难度在哪儿呢？就是因为它们这个叫异构集群多芯片的组合，这个是可以实现的。但是尤其是我长期，如果是我新老交替，我还不断的叠加新的进来，那我的难度会越来越大。没必要，因为这里面两个，一个是不同的芯片的难度，我们

这红圈画的不同的芯片的难度，各家不一样。另一个即使我们这个黑圈画的，即使是一个公司，我的芯片也不断迭代的，比如说哪怕是英伟达，我过去是 H200，这个 A100 到现在这个 B200，我这也是在不断迭代的那这个我前后也是有代差的那也很麻烦，所以计算中心最好就不混。当然另外一个就是说异构模式，大家记不记得我们上次讲的叫 KV，就是所谓尤其你推理的时候叫 KV Cache，就是 KV 缓存，意思就是说等于是我如果反复调用这个数据的话，为了避免反复调用，我把一部分需要反复调用的东西给它存起来，所以这个就能够使得我们的计算能够做到不用反复调用就省钱，尤其省 Token。现在这块都变成了一个业内共识，都是这么去做的。就现在叫做 PD 分离，叫 Prefill 和 Decode 的分离。Prefill 就是这个等于是先处理输入上下文，先把上下文要输入进去，Decode 等于是我在做计算再吐出来？那这两个原来是一体化的，现在都可以分离开。

科技特训营

Prefill/Decode 分离：相对有希望的异构模式



PD分离的原理

大模型推理计算可以分为Prefill与Decode两个阶段
 Prefill: 处理输入上下文，矩阵计算，密集大相对规模
 Decode: 逐个生成Token，依赖显存带宽
 PD分离将两阶段交给不同的芯片池，再传输KV Cache实现异构芯片协作

Kimi与清华大学的研究发现

该研究中32张H200做Prefill + 64张H20做P/D池：相对96张H200同构基线，吞吐+54%，首Token延迟-64%，研究认为在万卡级别的即便异地数据中心调度，满足1.8 Tbps带宽需求（225GB/s）依然能实现理论上的效果
 注意：结果依赖请求分布与特定模型，不代表所有国产芯片均可复制

然后对这个肖邦问的挺好的，王老师每次课程讲完可不可以有一些划重点的笔记给到同学们。这个是可以，这没问题，我觉得也应该做。当然一方面其实也不难，就是你自己也可以做。就是你把我说的内容已经有同学这么干了。咱们同学里还是卧虎藏龙的，有同学甚至听我这东西都觉得废话太多，怎么办呢？就让人工智能听完这个视频，然后把它总结成 20 分钟的概要，他再听这 20 分钟就行了。所以你这也是划重点笔记，你希望多长时间两分钟看完？但是是可以做的，但是肯定不是我做，就是 NotebookLM 或者是别的大模型来做。但是这个思路是可以的，但是还是一样。我希望大家思路的时候，因为我的很多唠叨也有点价值，就有时间来听听洗洗脑也挺好的，因为尤其是很多关联性的东西它会可能会被过

滤掉了，所以也是一样。然后这个 Carl 说 KV Cache 存前面的、反复的，后面再算费用。是的，这个特别好啊。所以现在这个逻辑是什么？就是这整个系统慢慢成型了，一个是所以叫 PD 分离，一个是 KV Cache。但是加在一起，实际上强调的都是在推理上现在效果其实是越来越好。而且是当然带来另一个问题，因为所有这些东西上了以后，注意推理的时候，中国并不比国外的成本格外便宜，这是另一个问题。

科技特训营

国产芯片的关键进展：华为950系列的FP8适配



950PR

面向Prefill/推荐
官方计划2026Q1可获得

950DT

面向Decode/训练
官方计划2026Q4可获得

精度支持

支持FP8当前主流模型训练精度，可以进一步提高推理阶段的生产效率，降低模型训练后的适配工作

就是我们刚才讲过中国比国外是有便宜的空间的，尤其现在中国的在国际上给的价钱是比国外便宜很多。但是这并不是成本的便宜，也就是说成本上并没比别人便宜了那么多，所以这个长期看都是有问题的。我们是不是永远能用低价策略，甚至将来可能人家拿来说事儿。因为这反倾销的核心就是你成本并没那么便宜，但是你做低价，所以某一天会不会有人站出来说，你中国其实背后也用的是英伟达。然后所以你的每百万 Token 你的成本并没那么低，但是你卖那么低的价钱。当然话说回来，这中间的空间就很大，就是说我怎么省的钱，我也是个逻辑所以你看这个就叫 PD 分离。很多时候它其实当然一个是速度，就是说这样我能够响应速度快，另一个其实也是便宜。所以未来这方面的竞争还是会，尤其这方面很多的这个进展还是会持续不断的，我们还可以关注。当然还是一样，就有很多是技术细节，技术上讲，我们就强调说唯一需要说的就是不用担心这个 Token 太贵。就 Token 短期内不太会变成这个大白菜，不太会特别的便宜。但是至少会持续下降，这是没有问题的。另外一个就是从长期看，当然是 Token 肯定是至少不应该是你考虑做业务的最主要的东西，或者说我做业务就是为了省

钱。那你可能今天、明天，甚至一年之后还有市场，但是两年之后就没有了，那这种事情就不值得做，就是要做一个更长期的事情。所以这个叫战术级这个算力会持续上升，继续能力会扩大。然后这个钱会越来越便宜，虽然我们花的钱会越来越多，但是我把别处钱挪到这儿来了。因为我这方面能满足我的需求更多，但是实际上整体来看，我每做一件事的成本其实是越来越低的，这是战术级。

科技特训营

DeepSeek/智谱造芯传闻？2年以上的故事



为什么先做推理ASIC

模型公司最了解算子与Token成本，在模型路径没有颠覆式变化的情况下，推理工作负载稳定，适合定制，但芯片定制本身需要大量时间和资源，即便AI加持下2年完成小规模验证也是当前的理论极限，大规模量产到具备产业影响需要更长时间

但是战略级的核心是什么呢？就是我们强调说首先需求是从市场层面爆发的，不是政府主导的，不是某人号召的，不是虚假的，而是每个人在不断的使用，每个人在大量使用，每个程序员在使用，每个业务人员在使用，所以这个需求是扎实的，当然国内外都在爆发，我们想告诉大家这一点，不只是国外爆发，国内也在爆发。这个需求爆发的满足，注意是更多靠市场行为来满足，不是靠国家队满足的。那市场行为满足，那些大 IT 企业有自己的算盘，所以你要知道他会怎么去做，所以这是这叫战略级的事情。当然如果碰巧你是大 IT 企业，你就可以有自己的策略。但是你不是，怎么跟它竞争？那也要想明白对吧？所以就是包括像 DeepSeek 这样的企业，他之前有人说过，DeepSeek 他如果是之前在量化上赚的盆满钵满，所以他应该不愁钱。但是我跟你讲，量化这件事就是个双刃剑，为什么你想这件事儿我一直不认为应该把道德这件事或者把情怀这件事放到一个企业运营当中去。太多地思考，因为一定是商业价值是第一位的。尤其我们如果你上我课就知道，其实这个我还是挺认同工业革命以来，人类社会普遍的越来越好。但是我认为这不是因为企业家都有良心了，是因为现在的竞争的模式就是你让更多人赚少点的钱，你就能变成巨富，你让少数人赚更多的钱，反倒变不成

【课程入口】公众号“全球风口”进入特训营

那么富。所以就是说赚钱的模式很重要，变成巨富的模式使得人都更温情脉脉了。那么这种时候就是这个，简单的说到 DeepSeek 也是一样。我们先判断它商业是不是能成立，然后再说这个商业成立它可不可以去持续，如果说商业都不成立，大家都做慈善，那怎么可能持续呢？包括我们自己，大家知道我做手环的这个原则就是便宜，但是你说我是因为善良，那我自认还是挺善良的，没人不自认善良，这个 Anthropic 那 CEO 还自认善良的，但是这事不靠谱，你也不要相信我是因为善良想做好事。

而反过来讲，因为我研究透了工业革命以来的精髓，就是让多数人得小便宜，好过让少数人得大便宜，让多数人花一点点钱就能得到好处，要好于少数人就花好多钱。所以我是看明白这个模式，我认为我们很幸福就在这儿。我们顺应这个时代就能把事做成。顺应这个时代就要尽量当好人，尽量服务更多人，就是顺应时代，利他说得非常对，但是严格说也不是完全利他，因为我还是要收钱，然后这业务能持续。所以这个是特别有意思，就是人类社会之所以到今天的伟大，不是因为我们的伟大的人更多了，而是因为伟大能成就更多人，能让更多人有成就。那大家就会选择伟大，你想想看在兵荒马乱的时代，自保才能活下来。大多数人会选择什么？会选择自保，这不是很简单的道理，所以我们认为我们首先要承认自己很幸运生在了一个伟大的时代。其次就要不辜负这个时代，在这个时代按这个时代的事情做点伟大的事情。



第三篇 中国AI算力产业评估


逍遥说的非常好，伟大的模式，所以这个是最重要的那好，回来了，我为什

么要说那么多？因为量化这个模式迄今为止，但是在全世界没有被认可，说它是有什么具体的价值，什么意思？都知道量化中国也赚很多钱，美国也赚很多钱。但是这个赚钱在美国还好，美国是什么？法不禁止皆可为。中国是什么？就我们叫天下为公，我们还是有所谓价值观念区别的，所以我很相信这个梁文锋，他为什么花那么多钱做 DeepSeek，包括为什么他现在愿意甚至说国家队来投资他做，他自己也投资很多钱做 DeepSeek。因为有了这张牌，它的量化才能更安全。我阴谋论一点，因为量化在中国先天就带着这个容易被人批评的地方。就因为他别的啥也没干，就是从买卖当中赚钱。那不是典型的资本家吗？就是倒买倒卖的新方式，所以这个很重要，就是中国过去都是这么一个逻辑，大家总结得比我好啊，存活下去、投名状和割韭菜。就是很简单，就是我而且中国这件事是对的，我们原来总结过好多年以前总结过，就是你如果被中国立成好典型，你就会安全一点，就是有点小坏事，就没人追究你了。你如果被人立成坏典型，那麻烦了，你又做过什么好事儿，也不会被提起了，似乎你只干过坏事，所以悦行远方说交易税，是不是税不知道，反正至少梁文锋做是很聪明的。因为我能够从另一件事上获得巨大的收益，所以我可以在这件事儿上只希望有巨大的名声，不希望有收益，或者说不在乎收益。但是你知道这个问题在哪儿？问题在你如果拿了别人的钱就麻烦了。我们刚才大家记不记得我开头说对吧？就是这些中国的大模型公司，你没上市之前都是香饽饽。因为如果你哪怕你是百亿市值，我只要认为你上市时候能成为千亿市值，我可以不介意给你十个亿，但是你上完市之后，那就是你收入利润撑不撑得起这市值，撑不起我就要做空你了。所以这个是不靠谱的，哈哈，所以我们要知道。然后他们造芯片，刚才芯片这个故事稍微说一下，这是个假的故事，这是个两年以上的故事了。就是说他们声称要制造芯片，那你说他可不可以造芯片呢？就是理论上说你是做人工智能算法的，因为今天的芯片叫 ASIC 芯片。ASIC 芯片的核心把你的算法固化到这个芯片里，为你专门做的芯片。但是问题来了，所以多数情况下确实是从芯片设计上讲，你是芯片应用方，你的大模型公司，你会对芯片的设计会有更有感觉。但问题来了，芯片的制造生产是完全另一套的东西，从流片到后面一系列的操作，封装等等等等，那是完全另外的东西。也就是说，一个芯片设计公司要跑通，把自己的芯片做出来，要大量的配合，所以我们在国外甚至还好一点。比如说国外很多人也在做芯片，它有一个选择就是

这个叫博通 Broadcom。那也就是说包括 TPU 都是博通帮他做，中国的博通是谁？我们今天下午还在跟同事讨论这些问题，我就问了中国博通是谁？如果有告诉我，这个其实不明显，肯定很多人声称是啊，但是没做到人家那水平，你不能帮人做到这个水平的话，你就不行。

科技特训营

趋势一：需求换挡，训练份额下降



所以那我自己搞，我也可以搞，不是不可以搞，砸好多钱，好多的试错成本，这方面请参考这个雷军讲自己做芯片的故事。所以这块儿就意味着说很难，表面看是你懂，但实际上就怎么生产出来，这个要大量的 know how，所以这就很难，所以我们说造芯不能等了，中国 AI 算力的产业评估，然后第一个就是训练份额下降，这是这个图，刚才给大家已经看过了，训练份额下降，推理的需求爆发，有了一个产业窗口。也就是说因为刚才说过了，训练就免谈了，就华为的事儿，无外乎就是华为、英伟达。推理就大家都可以进来。

趋势二：国家级算力过剩，不是产业主导



国家级算力名义规模巨大

约1085万架标准机架，平均上架率约60%
名义总算力约962 EFLOPS（FP32折算）
国家超算互联网接入超20万张GPU卡

国家级算力过剩

发改委网站刊载的专家文章提到部分西部中心
空置率超过50%、个别机架上架率不足10%；
Reuters 调查称许多受访地方政府支持中心负载
约20%—30%，18个月内取消项目超过100个

另外一个注意很重要，推理市场进来以后，国家级算力中心过剩，所以国家没有办法成为产业主导。它要主导，规则就不一样。但是他过剩，而且空置率很高，部分西部中心的空间率超过50%，个别机架上架率不到10%，路透的调查显示许多受访地方政府支持中心负载大约20%到30%，18个月内取消项目超过100个。简单说就是很热就做了，后来发现也没需求，因为这个需求不是你建计算中心需求就来的。需求是从哪儿来的？需求从大模型来那你手里有没有大模型，你没有，那谁找你。

趋势三：中国推理芯片窗口成为市场共识



字节高通合作传闻的演化

2026年5月，彭博援引知情人士称，高通已与字节跳动达成数据中心AI芯片合作。字节计划采购数百万颗高通AI ASIC，主要用于支撑AI智能体软件和相关推理负载；字节也将成为高通数据中心定制ASIC业务的首批重要客户之一。双方均未正式确认，路透也表示无法独立核实。


2026年6月，路透又披露了更进一步的合作讨论：高通正与字节商谈提供定制芯片设计服务，可能部分使用高通收购的高速互联公司AlphaWave Semi的技术；其中一个潜在方向是视频处理器VPU，目标可能是2026年底启动量产。不过这一轮谈判尚未最终确定，字节仍可能选择其他合作伙伴。

然后第三个，中国推理芯片这个窗口成为市场窗口。什么叫窗口呢？就是未来这段时间，中国推理芯片的竞争极其激烈，一方面中国我们说了三个梯队。注意三个梯队只有第三梯队是独立创业公司是相对难的，第三梯队有可能有胜出者，

但是最肥的两块第一第二梯队都不是独立创业公司，他们更容易赢。那华为肯定更容易赢，因为连这个训练都是华为的，阿里更容易赢，因为我本来就有云，我本来就做芯片，我自己就可以用，我独立芯片公司又没有云又没有大模型，我来做就很难。但是雪上加霜的是还有人往里跳，高通又和字节达成数据中心的 AI 芯片合作，字节计划采购数百 MW 高通 AI ASIC 芯片，高通在切进来。所以 AI 的高通版的 GPU，当然可以叫 NPU，可以叫别的什么 PU，就是我用专门做支持人工智能计算的，所以你看而且 2026 年路透披露了进一步的合作讨论，就是高通正在和字节商谈提供定制化芯片设计服务。也就是说刚才我们说过了，就是说你这个定制芯片，你需要有很多的经验，你没做过，不是不能做，表面看没难度，而且你了解要什么，但实际上这个 know-how 太多。所以当然一个可能就是你跟博通去 Broadcom 去谈，另一个就是它跟高通谈，高通本来想切进这块，对博通而言你只是客户，高通而言是我开拓一个新生意，所以高通肯定更积极对吧？那字节也很好啊，这样我就有机会跟你玩儿了。所以就等于说是我另一种模式能够实现，我也有芯片，你看它要做了以后，那就高通芯片进来，甚至将来卖的时候都会变成可能字节芯片，那又一块儿就是这个二梯队又一个强手加入，所以这就很麻烦。

科技特训营

供给/资产测算2026国产AI芯片市场规模



好，那我们再来算算账，就 2026 年的这个国产的 AI 芯片的市场规模，基本上我们说这个产能大概是芯片市场的上限在 600 亿到 1190 亿之间的规模，预算基本上差不多在 1000 亿到 1200 亿之间。所以我们基本上大致判断的就是主要是国产的产能。我们基于这样判断，就是大约是在 800 到 1000 亿左右，就是

[【课程入口】公众号“全球风口”进入特训营](#)

2026 年、2027 年应该差不多，可能略有上涨，涨不太多，但后面才会有逐渐的上涨，就是我们说每年的上涨。

科技特训营

2026—2029 国产 AI 芯片市场空间估算



年份	下行 (亿元)	基准 (亿元)	上行 (亿元)
2026	700—950	800—1100	1000—1300
2027	600—850	900—1300	1350—1900
2028	700—1050	1150—1650	1850—2600
2029	850—1300	1450—2100	2400—3300

然后 2027 年可能是 1300 到 1900，2028 年就涨得快点了，2029 年涨得更快，就是到 2000 到 3000。所以基本上我们之前我觉得跟大家说过，注意这我要做一些修正。就是说之前我们说过，如果是按以前我们觉得是以国家队来建设为主的这么一个估算。那如果是中国有 1000 亿的芯片市场，那其中可能 800 亿是属于第一二梯队，剩下 200 亿的政府主导会愿意分到第三梯队的这些地方创业公司，因为这样能分散风险，因为说白了第二梯队政府都有不信任的理由。但是现在看，如果主导这一期 1000 亿，主要就是大 IT 公司花的，那你猜他会怎么花？首先我得完成任务，所以一定会多花钱买华为的。我得先花自己的买自己的，所以是阿里平头哥，所以是昆仑芯，所以是字节自己，对不对？然后剩下才是给第三梯队，而且第三梯队就不会再太分配，上次说的 200 亿还分配给五家，不太会了。所以第三梯队很可能胜出的就两三家。注意这是区别。我原来以为第三梯队可以有五家以上的存活率，现在看起来因为整个结构不是这样的，所以第三梯队的存活数量可能会降到两三家，而且两三家到最后其实头部还是那么大。因为这整体是第三梯队，给第三梯队留的空间也没有以前想的那么大。当然还有一个好玩儿的事儿，就国外我们就知道上下游在锁定，中国没有上下游锁定的消息，注意没有上下游锁定消息，为什么？不是不想锁定，是什么？就是基本上在确认我们的观点。想想看，如果你有国产芯片的提供能力，哪怕你是推理芯片。那如果我芯片长期是需求不能满足，那我要不要跟你谈锁定？应该是要的，对不对？

【课程入口】公众号“全球风口”进入特训营

产业上下游走向锁定，芯片厂商站在最后的窗口期

国内确实严重缺乏GPU或ASIC的算力产能。但这一问题目前正在得到解决，因为中国设计的ASIC正从国内晶圆厂以及周边国家的晶圆厂中获得更多的供应。聪明的供应商不会坐视（涨价）不管...他们有着非常明确的前瞻性视野，并通过谈判签订长期协议，以确保其未来3到5年的收入前景具有确定性。

——罗硕瀚（腾讯CFO）

大家都愿意尝试自研芯片，这对行业来说是好事。但芯片研发的门槛很高.....在这个过程中，跟不上行业节奏的团队肯定会被淘汰...从产业发展的角度来看，最终不会形成每家公司都养一个芯片团队、内部自成体系的局面，还是会出现一批头部的芯片公司，支撑整个产业的算力需求。

——欧阳剑（百度昆仑芯 CEO）

基于客户需求和在手订单情况，相较于上个季度，公司对于今年的整体运营情况更加乐观。主要是因为，人工智能对配套芯片的强劲需求，直接推动电源管理芯片产能供不应求，亦带动电动汽车、机器人等新应用需求；虹吸效应使得消费、IOT等客户在大陆寻找产能、订单回流；产业链国产化诉求，推动国产逻辑、网通等芯片需求，还有提前备货...公司继续推进产能建设，与客户签订长期协议，锁定未来需求，为公司带来稳健的增长动能。

——赵海军（中芯国际CEO）

但是为什么现在一个锁定的消息都没出来？迄今为止没有一个锁定的消息放不出来。因为真正能够满足需求的就是这个头部，就是华为和阿里。华为肯定不用放这种消息，我是华为，我不需要锁定，我也供不应求。锁定了以后我涨价还不方便，只有国外某个霸王条款是我们之前讲过了，锁定的同时还得说我随时可以涨价，而且涨价了你还得锁定。那这种太过霸王条款了，所以首先就是说华为不需要，其实阿里没啥可锁定的，我供应内部都不一定够我锁定啥，剩下为什么没有锁定了，其他小公司根本不值得我锁定。锁定你得有这能力，我才我相信你有这个能力才锁定，我相信你是英伟达我才锁定，你赶紧要交付给我，如果你就不能交付，咱俩锁定有啥用，所以没有一个锁定的原因就在于不是不想锁定，而是没人可锁定。头部都不需要锁定，尾部都不值得锁定。预算是1000亿左右，空间是这么大，尤其这几个大IT公司就是主流，我们讲的就是跟国外其实是有很大的相似性。国外也是，发现没有，一开始也是主要是IT公司的投资，中国也在走这条路，因为他们也是最大的受益者，所以中国和国外总的来说整体结构还是有很强的相似性的。

企业：需求窗口与产能限制中能否绑定少数客户

2029年50倍成熟PE、30%净利率反推营收规模

公司	市值快照 (7月15日)	2029年成熟收入规模
寒武纪	8400.28亿元	约560亿元
海光信息	7479.02亿元	约499亿元
摩尔线程	3003.43亿元	约200亿元
沐曦	3364.84亿元	约224亿元



中芯国际先进产能归属头部企业


情景	第一大客户占先进产能	前五大合计
较分散	25%	83%
基准	48%	90%
高度集中	70%	94%

中芯国际披露第一大客户收入占比：8.0%，前五大客户收入占比：35.8%，按照先进芯片产能2万片以内的规模估算

然后这个时候，我们就算一下说第一个企业的生存就很关键了，尤其是头部不用说了，但是头部也没得谈，不是上市公司。剩下的这些后面的公司谁能生存，谁能活得好，这个我们叫需求窗口和产能限制。一方面需求有窗口，另一方面产能能力不足。这个时候你能不能绑定客户？也就是说这时候你如果能够，为什么还是刚才那个 PPT？大家记不记得我们说现在没有一个确定的公布。那有人会说，那他不公布锁定，但是为什么不应该是这样？因为如果你能拿到锁定，哪怕你是寒武纪，你能拿到锁定订单，你一定会公布。因为你的现在的收入根本不能支撑你的股价，你不担心股价下跌吗？那你肯定要给自己的未来发展提供支撑，一个很好的支撑就是公布我已经锁定了订单了，所以国外就是公布，我公布你看我锁定了未来三年订单了，那我不就踏实了。所以中国一个公布都没有，那就是真的不是不想公布，而是没有拿着订单。如果他绑定了少数客户，绑定了少数大客户，实现了这个锁定，对他来说是重大利好。谁不想要重大利好？不是不想，是没有好吧。但是为什么想要重大利好？因为真的需要，你看他现在是啥水平，我们就看寒武纪，7月15号，今天16号，昨天的市值8400亿，然后我们算一个什么呢？一个公司如果是确实是持续快速上涨，只不过不是爆炸性上涨，那我们认为50倍PE是可以的。另外一个就是净利润30%是相当不错的了，内存短缺我上次讲过了，内存现在是短缺，这两三年应该都恢复不了。但是长期这个短缺内存短缺的恢复主要是一个生产建设周期的问题，两三年的时间我上次讲过了。所以注意寒武纪如果说2029年做到了50倍的成熟PE，我们认为是一个高增长公司的一个理想的PE同时能做到30%的净利润，是一个不错的芯片公司的利润率，这

时候它的收入规模要做到多少？要支撑现在的市值，这不是未来市值，就是 2029 年能够支撑到今天的 8400 亿的市值。它需要做到 560 亿收入，它今天有多少收入呢？65 亿，所以差多少？差八倍。就是说它 2025 年的收入是 65 亿，6、7、8、9 四年时间能不能翻八倍？能，你就能撑得住今天的市值。不能，你今天的市值都撑不住。大家理解我的话了吧？嗯，那我同样去计算，比如说海光，海光现在是多少？这个收入是 100 亿，它的市值是 7400 亿。如果当然海光很可能这个利润不见得会那么高，但是如果也这么算，它到 2029 年的时候，需要做到今天市值的话，需要做到 499 亿，不到 500 亿的水平。那今天 140 亿能翻三倍的话，那是不是就可以了，估值方法我说了，就是 29 年如果是 50 倍 PE、30% 的净利润率的话，那你现在估值是多少？到时候营收是多少，或者反过来，我营收是多少就应该估值是多少。你算一下估计预计的营收，当然这里面不会特别准确，一定是个数量级的问题。所以就还是这个逻辑说你现在和未来有着差不多十倍，一个位数的数量级，有十倍数量级，那你四年能不能翻十倍？这是一个问题，摩尔线程也是一样需要 200 亿。但是今天 15.1 亿差着不止十倍？沐曦今天 16.4 亿需要 220 亿，就是差距不止十倍。所以这是特别大的一个问题，所以这是一个就对他们而言，我认为就都要好好计算。他未来简单说中间可能有极少数能够达到这个水平，就是能够最后真的实现了十倍增长，十倍收入增长，但是一定不会是普遍的，因为什么？因为我们刚才讲过了，我如果是大 IT 公司主导的话，那我就一定是批量的采购，然后嘉琛说的非常好，这个补充很好，我查到寒武纪市场份额显著高于平头哥和昆仑芯。但是问题是他多少钱？他现在寒武纪也就 65 亿，65 亿你算一算，假设一个芯片 5 万块钱，你除以 5 万，就是 10 万颗芯片的水平。就是说寒武纪正在跨过这个万卡的供应能力，这个是它的好消息。但是坏消息什么呢？它也没有那么大，什么意思呢？就是说这个平头哥和昆仑芯我们讲过了，它有自己的云计算要支持，所以我自己的云计算计算可能就会消耗我的 10 万个卡。意味着说，富小闲我也同意，寒武纪就不会高于平头哥。那意味着平头哥和昆仑芯因为有 IT 平台做支撑，或者顺便讲，你说如果刚才我们说的高通和字节的合作成功了，那你猜字节会采购多少高通/字节的芯片呢？至少 10 万起，所以就是说是的，阿里思雨说平头哥出货金额超过百亿，是的，就是这道理，因为人家是 IT 公司。

2029年国产芯片市场格局预估



国产芯片格局的未来演化趋势

2026是供给决定份额，2027是商业客户锁定，2028是软件与新代产品筛选，2029则出现平台化与专用ASIC并存。随着推理国产化加深，市场规模扩大（按2400亿），头部集中，华为预计将占据主力，头部互联网厂商自产芯片成为第二梯队，独立第三方芯片厂商瓜分剩余市场。

然后 Kevin 卢说：问题是刚刚的模型公司用的都是华为的，这些增长来自于公司采购。就是还得细听，刚才我说的那些模型公司用的是华为的，推理可以用别人的，这些公司的增长都来自于推理。但是这个也提醒我了，顺便说的非常好说的非常好。这个提醒的好就是什么呢？在这个 1000 亿里，训练和推理一定是训练至少要占到 30%，训练至少 30%，所以大家分不了所有的市场，只能分一半的市场，或者是 60%、70%最多了。那个市场就是推理市场能分，训练市场只能归华为。然后嘉琛说：寒武纪目前互联能力虽有优化，最大规模只能支持数千卡规模集群规模在两三千卡。是的，但是 2 到 3000 卡的我们刚才也说过，2 到 3000 卡推理是够用的。推理是不用万卡，是两三千卡够用，就是你一堆的千卡集群或者百卡集群来支持一个大的推理的算力中心是够用的。这也像我刚才说过的，李永峰你能不能看我 PPT？29 年如果是现在的市值是 8400 亿，然后如果你 29 年的时候是 50 倍 PE、30%净利润就能推出来，你到时候要支撑住 8400 亿的市值，需要 560 亿元好吧，因为 50 倍的 PE 是一个科技公司的一个还是相当不错的估值。所以我们估计未来的市场很有可能，但是这个估计，因为我们没有 HBM，现在有华为自己来搞自己 HBM，而且 HBM 也没对中国封锁。所以我现在是保守估计，因为怕把华为夸得再大了，我这已经尽量保守的估计了，未来市场里面市场占比华为至少 50%，然后阿里、百度等二梯队，当然也包括刚才说的字节 2 梯队，所以叫 IT 公司会占 30%，独立第三方空间只有 20%。但实际上很有可能比这小的多，很有可能独立第三方只有 10%甚至更小。这是一个估计，所以就是说这个国内估值太高了，张说的话就是我说的话。

直播要点：

1. **需求层**：平台广告推荐、多模态、编程等算力需求增长迅猛，AI算力已经成为需求拉动、健康发展的真实市场，未来还会进一步高速增长。
2. **模型层**：Scaling law 没有失效，大模型仍需持续、巨额投资来支撑需求，独立上市的国产大模型公司处于劣势，互联网大公司更容易砸钱维持领先
3. **模型层**：编程是全球统一需求，中国长期与国外有差距，多模态等细分领域中国有数据优势，有望在全球市场拿下份额；头部大模型公司能否做出细分定位，放弃AGI故事，是重要的未来信号
4. **芯片层**：训练与推理正分裂成两个市场，训练本质是通讯/工程问题，依赖芯片和芯片集群；推理更多是性能调优与资源调度
5. **芯片层**：训练看华为，推理市场红海化。制造与平台都将走向集中，华为依靠训练/推理将保持一梯队领先，大 IT 公司有望在推理市场进入二梯队，独立芯片公司将决战三梯队站位，同时面临国外厂商挑战
6. **芯片层**：第三梯队企业当下面对的不是增长问题，2029年的淘汰赛已经启动，谁能存活才是关键

所以结论是什么？结论是我们今天不是在讨论哪个第三梯队的芯片公司会大涨，而是在讨论哪个第三梯队的芯片公司会不死，这就是今天的结果。好，然后直播要点还是一样，需求层就是很明确，需求增长迅猛，但是市场拉动的不是规定动作，模型层必须要继续支撑巨额投资，独立上市的大模型公司就会有问题，互联网公司因为它本身有需求，它就会容易继续砸钱，DeepSeek 是另一种需求，也会砸钱，模型层这个编程的市场是全球统一的需求，中国不一定能够特别领先，但是多模态细分市场中国有领先优势，而且有全球领先这样的优势机会，所以要全球化，要走出去。而且多模态上面如果中国能够走出去，甚至说独立的大模型公司，也和国内的这种大 IT 公司有一战之力，但是独立大模型公司千万别被忽悠晕了头了，MiniMax 那哥们儿自称说 AGI 之前不领薪水，我估计未来 20 年他就当雷锋，就领不着薪水。但是他可以用别的办法领薪水，或者卖点股权，卖点期权，那是另外的事儿，但是反正薪水是领不着了。然后芯片层也是让大家理解，训练和推理是两个芯片，两个市场。训练市场基本上就是英伟达、华为，华为现在看起来有一定的经验，还没有广泛铺开的经验。所以我认为在训练市场里面，未来至少两三年的时间，至少两三年应该还是尽量要用英伟达帮着撑一撑的，要不然会影响我们的训练。而推理就是大家都在抢，但是上规模是第一要务，谁能上规模谁最有可能活，因为活的空间不大。因为我们说我说的客气点，就是华为 50%，二梯队 30%，三梯队 20%，但是二梯队可能更高，三梯队可能是 10% 对吧？但是实际说的客观一点，我认为是华为是 60 到 80，那二梯队是 20 到 30，三梯队是 10 都不到。因为没必要，我干嘛要去搞八制？这个国家队需要七国八制。

我是字节，我作为平台，我弄七国八制不是给自己添堵吗？而且何况有一个七国八制还是必须要应对的，就是我自己芯片还有升级的，一个公司芯片还要去做适配，我再引入多个公司，那不是找麻烦。所以引入多个公司可能就是可能性并不大。如果都是他们主导的话，他们又不影响多个小公司的生存，就会受到严重的挑战。当然你说现在为什么还有生存的空间？因为在过去这一两年里，谁还在给他们订单？比如说时不时能够见到订单里说有寒武纪的，就是我们的国家队主导者，就是电信、联通、移动。但是问题是现在这两年建设周期也是热的这个过程中，你买了一些寒武纪是可能的。但是未来我们说了国家队它饱和，那怎么办？所以说的不客气点儿，包括寒武纪在内都有可能未来都很麻烦。寒武纪说第一大客户是字节还是一样。那别忘了刚才字节还有一个供应商叫做高通，他在干嘛呢？还有另一个，寒武纪说第一大客户是字节，但是在字节眼里，它的第一大供应商是华为。理解我的意思了吧？所以一定要就是我们对产业分析一定要客观，一定要冷血一点的去分析，能看到事实。当然我们都希望创业公司很好，但是真的没那么容易，所以训练看华为，推理是红海，然后推理谁能赢，就看谁能玩命上量。而这个上量面临挑战，这个很麻烦。大多数高科技都很短命。是的。好，芯片层第三梯队核心是淘汰问题，淘汰现在已经开始了，这就是我们今天讲的好吧，就是我在尽量迎合大家购买股票的心理。但是在这个板块里我想跟大家的结论是，大家不要轻易炒芯片公司。因为它更多的问题是未来谁会死，而不是未来谁会十倍的增长。这也很重要。还是我们强调的，投资的安全性要大于投资增长性。我们今天讲的是安全感，千万不要被某个芯片公司忽悠了。因为你知道我也是一个被忽悠的重灾区。很多人都认为忽悠了我替他说句话会有点用，所以所以你们也就尽量别被忽悠了。海光有的 GPU 也只是推理的，不是训练的。好，这么多，然后答疑，互动提问。

互动提问（上）：

01. 【郑新芬】：我国运载火箭已经实现首次一级可控回收，长期看是否看好中国商业航天的发展？
02. 【悦行远方】：王老师，我有五个问题请您点评：1) 我对您的中观分析框架有一些新的理解：技术要站在科学家和工程师角度考虑，产业要站在国家角度考虑，应用要站在用户角度考虑，企业要站在老板角度考虑。这样理解是否合理？2) 目前市场关注的焦点仍集中在算力、存储等基础设施，但AI应用、端侧AI开始逐步成熟，您觉得未来AI应用爆发的节奏是怎么样的？应用爆发以后，会取代基础设施成为新的主线，还是形成“应用验证需求、基础设施继续扩张”的双轮驱动？3) 阶跃星辰7月13日发布了STEPX Neo智能体手机，您之前课程说过下半年会有各种各样的龙虾手机出来，您怎么看待这次阶跃星辰发布的AI手机？是不是逐渐开始爆发了？4) 美国的AI基础设施资本支出比中国大很多，中国未来靠什么追赶？虽然中国投入的钱更少，但建设和运营成本也更低，是否可能用更少的钱达到接近美国的效果？还是说差距会继续扩大？5) 华为是算力中心的头部企业，长鑫是存储的头部企业，他们是有定价权的，那么对于华为和长鑫的供应商来说，是否会增收不增利？
03. 【任勇】：对比英伟达产业链，国产算力产业链里最有长期价值的是哪一块？我认为封装领域，看似不亮眼，但技术含量还是相当高的。不知道对不对，只是浅见，请王老师指教。
04. 【语桐】：老师提到过美国的《拜杜法案》加速了高校科研专利成果向社会产品应用的快速转化，是美国科技驱动创新的原动力，这种高校擅长科研，创业者擅长将科研成果产品化，是一种很高效的社会化分工。我受到的启发是：在AI的加持下，人类的劳动可能会从大量不擅长、不得不做的标准化劳动中退出，转向自己更有比较优势也更擅长的核心能力上。AI负责补齐其余能力，并把不同人的成果连接，相互增强，实现个体价值与利益最大化。AI革命不仅解放人类的脑力劳动也解放人类的能力错配。请老师指正。
05. 【机器猫】：此前课程提到政策资金正在加强对资本市场的支持。中长期资金入市、中央汇金稳市工具与地方政府化债之间分别是什么关系？能否将其理解为“国家通过股市化债”？
06. 【张中杰】：新泽西州正在审议要求无人驾驶车辆使用摄像头之外至少两类独立传感器的法案，媒体称纽约州也可能提出类似要求。这类强制多传感器冗余的监管会如何发展？对纯视觉和多传感器路线分别有什么影响？

郑新芬说：我国运载火箭已经实现一次一级可控回收，长期怎么看中国商业航天的发展？长期看好中国航天，因为中国的航天要和美国对抗，中美航天都是以国家对抗为主的，它不是商业啊，所以长期不看好商业航天。因为商业航天的前提是有需求，美国的需求是两个，一个需求是国家，就是政府给了大量的商业公司项目，中国这个没有，因为政府会给长征项目，不给商业航天项目。就是中国的运载火箭，是中国的长征实现了运载火箭的一级回收，那是国家队，他不是商业航天，长征不是商业航天。第二个市场是太空互联网。对不起，中国20年之前就村村通了，太空互联网的市场也要远远小于美国。

嘉琛说：今年字节算力寒武纪份额多，明年就变成华为了。说的非常对，后年就变成华为加高通了，说的非常对，当然希望寒武纪能活，第三梯队总要有能活的，对吧？希望。

悦行远方说：王老师，我有五个问题请您点评。第一，我对您中观分析框架有一些新的理解。技术要站在科学家和工程师角度考虑，产业要站在国家角度考虑，应用要站在用户角度考虑，企业要站在老板角度考虑，这样理解是否合理？我觉得非常好非常非常好啊。当然稍微有点小的我们的讨论就是说技术不光是科学家，我们说这个三个角色，叫科学家，中国这个没有分开，叫 scientist、technician 和 engineer, engineer 是做规模化的。什么叫科学、技术和工程？这是三个东西。所以科学家、技术人员、工程师的角度到最后是工程师角度，最后是工程师角度。所以技术甚至你只站在工程师角度思考都没有错。因为工程师也要考虑技术的优势的，也没错，所以工程师角度更直接一点。产业其实不完全

是国家的角度，产业是站在产业生态的角度，是宏观一点角度，产业的把控者的角度，应用站在用户角度是没错的。当然用户也要分，就是有时候用户不知道自己需要什么，我也站在一个比较超然的角度。这个四个都一样。我们要站在什么，加一个角度，站在比较超然的工程师的角度，站在比较超然的产业的角度，和比较超然的用户的角度，和比较超然的企业的角度，你别陷进去。但是你说这四个角度非常棒，今天的这个我觉得应该你拿奖，后面这问题提的特别好。然后第二个，目前市场关注的焦点集中在算力存储的基础设施，现在 AI 应用、端侧应用开始逐步成熟。因为未来 AI 应用爆发的节奏是什么样的？应用爆发以后会取代基础设施为新的主线，而形成应用验证需求、新基础设施结构，然后反哺需求。应用会取代基础设施成为新主线是没有问题的，那应用的我们其实原来说过，就是今年希望开始有一些应用，移动应用开始试水，开始逐渐扩大了。尤其是过去的 AIGC 会逐渐变成叫 AIGS，就是提供服务，服务的核心叫做这个领域智能，叫做大行为模型。还是行为智能呢？手机和手机结合，这是最大的应用的机会，我们认为今年会开始，明后年会渐入佳境，而且会三年之后回头看，你会发现现在是个拐点。这之前的三年和之后的三年是两个逻辑。之前三年是 AIGC 的逻辑，只是生成内容。这之后三年是 AIGS 生成服务的逻辑。但核心是我对你的行为有理解，是行为智能的逻辑，是基于手机的，给你提供服务的逻辑，完全不一样的。第三，阶跃星辰 7 月 13 日发布了 STEPX Neo 智能体手机。之前课程说下半年会有各种各样小龙虾数据出来，怎么看待阶跃新发布 AI 手机是不是逐渐开始爆发了？我觉得他在开始这个明显的在抢热度，都不叫蹭热度。因为还没开始热，它在抢热度，刚才连手机都没有，所以就基本上是能够迎合我们的判断，就是他抢热度。因为他知道很快大家就会热了，就是他不宣布，他等到手机出来再宣布他前面有若干家，那说明什么什么下半年一定还有，是不是说明我们的判断是对的。第四，美国的 AI 基础设施资本支出比中国大很多，中国未来靠什么追赶？虽然中国投入钱更少，但相应的运营成本也更低，是有可能用更少钱的。这样美国的领先还是会继续扩大。第一个就是在大模型的基础水平上讲，还是会有差距的，而且不一定扩大。因为我们开源它总能跟上，这个软件东西，它就是它会扩散的，总能跟上，但是持续会有差距；第二个我们要追上怎么追呢？就在应用上，在我们有足够算力，有足够数据优势的局部集中局部算力、集中数据优势来

实现细分领域的突破。比如说视觉处理、视频处理。然后第五，华为是算力中心的头部企业，长鑫是存储头部企业，他们是有定价权的。那么对于华为长鑫供应商来说会增利，注意长鑫是存储头部企业，但是存储很少有定价权，大多数存储企业没有定价权，为什么？因为存储不稀缺，现在是赶上时候了，存储稀缺的时候。但是存储稀缺能稀缺多久？普通的存储 DRAM 可能稀缺 2 到 3 年，这个 HBM 可能会稀缺五年，仅此而已。所以在这个产业里，存储就不是产业头部。不是某个领域的头部不等于产业头部。所以是产业思维，在计算机这个产业里或者计算算力这个产业里，华为才是头部，长鑫不是头部。对于华为和长鑫供应商来说，是增利不增收。那就看第一你是不是稀缺？长鑫也是别人供应我就能增收，看你是不是相对稀缺，不可替代。另外一个就看你的供应商是不是有良心。

然后任勇说：对比因为大家产业链中国产算力产业链里最有长期价值是哪一块？我认为封装看似不亮眼，但具有含量相当高的，不知道对不对？这是全年相关的指教，都是一样，就是说有长期价值都是头部，这个头部有什么价值叫做华为，其他都是看运气看命，就是封装有至少有未来两三年的长期增长空间，因为长期会稀缺，或者长期会有独特的竞争壁垒。但是它的产业价值肯定就是很简单，产业链的实际价值就是头部。所以我们讲潮流产业的头部企业，封装是指这个芯片产业的心头部，不是，对不对？

然后 William 说：我是非法局法学员，想问关于台积电的问题，因为台积电发布业绩超预期，但是盘点股价大跌，目前台积电市值 2 点一二万亿，股价 409，因为台积电股价泡沫巨大，很多机构大家看到 5 万。不要看股价，股价没有意义，因为股价和你发多少股有关系。要看的是叫一个是市值的一个市盈率，还有一个叫市销率。因为很多公司市盈率会被藏住，因为我不想让这个盈利显那么高，我把它投到这个基础设施建设和我把它投到这个研发里，都能够藏市盈率。所以市销率你藏不掉，因为你卖多少东西，它是一个实际数，你卖了就卖了，没卖就没卖，所以要看一下台积电的市盈率市销率就能知道，这个是，但是我倾向于认为注意这个很好玩的事，虽然台积电这，谁能现场帮我查一下，你们谁帮我查一下？是台积电的市盈率、市销率只要不是特别过分，都是可以持有的。为什么呢？因为台积电被认为是一个生产企业，因为利润太薄。但实际上市盈率、市销率说的不是利润，说的是成长性。所以它的成长性只要足够好的话就可以。台积电市盈

率 35，35 是一个看起来不错的科技公司市盈率，但绝不是那个特别涨快速增长市盈率的第二台阶有可能快速增长。所以我会倾向于认为你放心持有台积电是没有问题的。这个 PS 是有没有 29.7，到底哪几个 PS16？Ok 对，反正简单说就是这个范围都是可以的。因为具体不用特别具体，这个范围它用来对标的是那个利润特别高的公司，就觉得你的这个你不应该那么高。但实际上他这个最主要要看他的成长性，就是他到底多少年能翻倍，成长性主要足够高的时候，这个市盈率就是挺好的。所以我认为可以长期持有的，因为它长期稀缺，而且还会稀缺，就是需求又扩大，它就会持续扩展，当然这个它有阶段性，就是它的扩展它不是连续扩展，它得是建一个厂就当就扩上去，管这个厂运营起来就扩展了一大块，对吧？所以你得有点耐心等着他下一个。比如说亚利桑的那个厂一旦建成，估计会跳起来一块，等一等。当然你要是说我要赌一把，我现在不着急投，我等到那个厂建成之前再投也不是不行，反正可以长期持有，然后。

语桐说：老师提到过美国的《拜杜法案》加速了高校科研专利成果向社会产品应用的快速转化，是美国科技创新驱动创新的原动力。这种高效擅长科研创业者擅长将科研成果转产品化，是一种高压社会化分工。我受到启示，在 AI 加持下，人类的劳动可能会从大量不擅长不得不做的标准化工程退出。然后自己更有比较优势也更有比较优势，也比较擅长。核心能力上 AI 负责补齐其余能力，并把不同的人的成果连接相互增强，实现个体价值与利益最大化。AI 革命不仅解放人类脑力劳动力，解放人类的能力错配清而执政。我觉得非常对，只不过就是从理论上说这是非常正确。但是从实践上来说，一般是反过来的。是我们在这个工作里面先把这个自己不擅长，但是机器又能做的大块工作外包出去。最后还会剩下一些自己也不擅长，但是机器也不擅长工作还得自己改。也就是说核心不是让这个人工智能来做所有的事儿，人类来补齐。而一般实践当中是看人工智能做什么，尽量人工智能做，然后人类补齐剩下的，就是这个马斯克在美国建汽车厂也是这个原则，就是让机器去完成尽量完成所有事儿，然后剩下的事儿让人来顶。所以人其实是更灵活，谁灵活谁查缺补漏。而且整体设计是人更擅长整体设计。所以人做整体设计，让人工智能去把主要部分替代掉，然后人把其他部分查缺补漏，把这个流程跑起来。但是逻辑是对的，非常对，这工业革命解放的是人类的能力错配，非常对。第二个好问题。

机器猫说：此前课程提到政策资金正在加强对资本上的支持，中长期资金入市，中央汇金稳定市场工具与地方政府发展之间分别有什么关系，能完全理解为国家通过股市化债。一部分，因为国家并不想，说白了这个是有个什么区别呢？就是稳定市场是国家策略，化债是地方策略，国家并不想什么都替地方担了，这不能多说了，国家地方也不是一体，不是同一个思维，大家还是有就我满足我的需求，所以国家是希望通过股市能够实现从过去的叫土地财政转向股权财政。但是通过股市化债一定程度是可以的，但是不是想买，因为以前大量城投债是个烂摊子，可能要别的事来玩。

然后张中杰说：新泽西州正在审议要求无人驾驶车辆使用摄像头之外至少两类独立传感器的法案。媒体称，纽约州可能也提出类似要求。这类强制多传感器冗余的监管会如何发展？对城市级和多传感流量并没有什么影响。因为我认为这个东西不容易通过。原因很简单，就是美国政府从来对科技就不敏感。他提科技要做什么，不做什么的事儿的时候，就很容易被科技批判。到最后因为很简单，你说你有那么多东西，你得比人家特斯拉强。特斯拉很容易说，我做实验，我就一个纯视觉，你是一堆传感器，咱俩谁牛就结束了，对不对？所以这个是被骂死的。当然这个中间会暴露另一个问题，就是我们强调的就是这件事出来只会加速，让特斯拉要赶紧。就是我大家记不记得我之前说的，一定要建立一个政府关系部门，就到这地步了。你都知道你的未来的发展就是无人驾驶出租车了，你竟然不要一个强力的政府关系部门，这是不可思议的事儿。我跟你说，这只能说马斯克真的心不在焉，都不用马克那水平，我这个水平都知道什么是最重要的，马斯克能不知道吗？他只是不在乎了，他正享受 SpaceX 那个万亿财富。

互动提问（下）：

07.【Janphone】：王老师，闭源AI巨头的商业模式是一边挣客户的钱，一边觊觎客户的数据和知识产权。就像Figma和Anthropic合作一样，Anthropic后来成立了claude design，我想问一下王老师：以后主权AI是不是一个趋势，算力，数据和模型都要攥在自己手里才可靠？以后如果开源模型能够干活了，本地算力加私有云加开源模型是不是一个趋势？Anthropic因为大家都怕和他合作，以后是不是前途也不够乐观？

08.【车纲】：目前中国算力市场一方面存在头部企业高端算力紧张、Agent和推理调用量快速增长的现象，另一方面又存在部分智算中心利用率不高、异构算力难以调度、算力资源与实际需求错配的问题。想请教王老师：随着AIGC向AIGS转变，中国算力市场未来真正稀缺的，是否会从单纯的芯片和峰值算力，转向能够为Agent提供稳定服务等级保障的“生产级可靠算力”？如果这一判断成立，未来评价一家算力公司、云平台或智算中心的核心指标，是否也应从卡数、峰值算力和机房利用率，逐步转向Agent任务完成率、端到端时延、服务可用率、故障恢复能力、弹性调度能力，以及“每完成一项有效任务的综合算力成本”？进一步看，在芯片厂商、算力中心、云平台、基础模型公司、Agent平台和行业应用公司之间，谁最有可能掌握这种可靠算力的定价权，并成为AIGS时代真正的产业利润中心？

09.【涂眠眠】：芯片设计、封装测试、散热、服务器集成、算力调度平台，这几个环节按“现阶段最值得集中力量突破”的重要性应如何排序？哪些环节正在进行真正的工程攻关，哪些环节讲故事的比例更高？

10.【凯凯苏】：1) MiniMax与智谱上市后市场表现明显分化。如何判断MiniMax近期大幅回撤是来自经营变化，还是估值、再融资稀释和市场预期调整？评价两家公司未来，应重点观察哪些经营指标？2) SHEIN未来增长主要来自哪些业务和地区？是创造新增需求、继续替代竞争对市场份额，还是向平台化和本地化扩张？海外监管会如何影响其增长上限？

11.【图南】：端侧AI手机的功能似乎已经逐渐齐全，但普通大众的新增换机动力在哪里？如果到2027年底仍找不到旧手机无法完成的核心场景，端侧AI是否只是“更好的同一代手机”？判断产业进入展开期，应该看“懒惰需求被击穿”，还是出现真正“过去做不到”的能力？

然后 Janphone 说：王老师，闭源 AI 巨头的商业模式是一边挣客户的钱，一边觊觎客户的数据和知识产权。就像 Figma 和 Anthropic 合作一样，Anthropic 后来成立了 claude design，我想问一下王老师：以后主权 AI 是不是一个趋势，算力，数据和模型都要攥在自己手里才可靠？以后如果开源模型能够干活了，本地算力加私有云加开源模型是不是一个趋势？Anthropic 因为大家都怕和他合作，以后是不是前途也不够乐观？不完全是，一定是一个长期博弈的结果。而且因为很简单，你自建你是安全，但是第一就是你短期内的效果可能没有我好啊，第二你成本一定是大的，那我就可以快速，还有你的竞争者的问题吗？我是你的竞争者，我去玩儿和 Anthropic 捆绑的路线，将来的套路我也无所谓，我最起码短期干过你。所以就说这个是一个复杂博弈，但是这个博弈会长期存在，这是肯定的。肯定很多公司还是宁肯用开源模型，宁肯自己本地算力加私有云，这是肯定的。但是顺便说一句，另一个就是很多东西当我们对说实话这是一个好玩儿的事儿。当我们对内容，尤其对内容的背景和它的相关性有足够的理解的时候，我们就会发现说大模型不是唯一的工具，或者不是最好的。比如举例来说，刚才跟我们讲，大家记不记得我一开始讲的那个就是叫 situated knowledge 这个叫立场性数据。甚至就是之前有人说用场景，情景化数据，都是对的，那我的现实的例子什么就还是用这个东西，我做这事儿特别好，就对我的这个对我自己对健康的理解都有巨对人工智能的理解都巨大进步。就是说我的健康数据是什么？我的健康数据不是现在的互联网上的这个公开数据，我不可能放在互联网上，那是疯了。但是我这数据，我也不是一堆的数，我是要数和一堆人关联起来，和人的时

间关联起来。随着大家的不同时间采集的数据才有意义，然后汇集到一起。然后还要分我们还在希望建立甚至家庭关系等等等等，这些才是未来的数据。所以简单说就是数据背后有很多就根本不是今天这格式。也就是说他现在互联网的格式跟我的不兼容，因为他我的格式需要区分人，需要区分时间，才行。所以简单说就是也不用太担心 Anthropic，就很多数据类型根本不是 Anthropic 能碰得着的，他也不理解。

车纲说：目前中国算力市场一方面存在头部企业高端算力紧张、Agent 和推理调用量快速增长的现象，另一方面又存在部分智算中心利用率不高、异构算力难以调度、算力资源与实际需求错配的问题。想请教王老师：随着 AIGC 向 AIGS 转变，中国算力市场未来真正稀缺的，是否会从单纯的芯片和峰值算力，转向能够为 Agent 提供稳定服务等级保障的“生产级可靠算力”？如果这一判断成立，未来评价一家算力公司、云平台或智算中心的核心指标，是否也应从卡数、峰值算力和机房利用率，逐步转向 Agent 任务完成率、端到端时延、服务可用率、故障等等等等，以及“每完成一项有效任务的综合算力成本”？进一步看，在芯片厂商等等之间，谁最有可能掌握这种可靠算力的定价权，并成为 AIGS 时代真正的产业利润中心？因为很简单，大家不是考虑这个算力本身了，就是说我考虑其实是用的什么模型，这个模型能够因为说白了就是你说你想这个你说的评判是对的，生产级可靠的人工智能输出，但生产力可靠人工智能输出核心你是看它模型是不是行，就模型能不能做到这个所谓叫比如说长效指标能不能做到完成这个长效任务？我们之前讲过了，现在衡量一个指标就是长效任务，你要做多长时间的任务，那这种时候看的其实不是算力，是模型。但你相信模型特别好，那它背后支持它的算力不会特别差。所以没有必要挑算力，挑模型就好了，但思路是对的。

涂眠眠说：芯片设计、封装测试、散热、服务器集成、算力调度平台，这几个环节按“现阶段最值得集中力量突破”的重要性应如何排序？哪些环节正在进行真正的工程攻关，哪些环节讲故事的比例更高？我是反过来想这件事，我只想这里哪一个事最重要，因为其他事不值得，就是第三第四没区别，第五没区别，后面都不值得看，就看最前面的，最前面是什么？最前面的我认为什么算力都不重要，最重要就是第一是服务器集成，第二算力调度平台。算力调度平台有可能未来几年越来越不发挥作用，因为如果都是以大算力集群为主的，就没啥可调度

的。调度的核心就是一堆的闲散算力和一堆的小模型，或者叫一堆开源模型在那跑。但未来这个格局有可能还是会存续，但是它在整个市场里的占比不大。

凯凯苏说：MiniMax 与智谱上市后市场表现明显分化。如何判断 MiniMax 近期大幅回撤究竟来自经营变化，还是估值、再融资稀释和市场预期调整？评价两家公司未来，应重点观察哪些经营指标？第一个，这个大幅度我根本不关心，就是我为何要去分析股市到底是怎么变动的？就是老百姓的这个群体愚蠢是怎么表现的？我对这没兴趣，我只想说的是说 MiniMax 智谱，现在问题就是说他现在的知识他之所以成立，就是他属于叫 GLM，这叫什么 GLM 这个 5.2 特别好，但是它的风险非常大。因为这个领域我们说过了，编程这件事儿是全球性的。你中国最好不代表你世界都能好，但世界比你很好很多你就完蛋，所以我不认为智谱长期会强，这个我之前也明确，而且智谱的出海？未来更有问题，因为它是清华，它有点政府背景，现在很多的说法故事也是拿了政企很多钱，所以业绩表现也很不错，这两点都不可持续。而 MiniMax 当然现在可能回撤很简单，国内挣不着钱，当然具体为什么这时候跌了那么多，我不知道，我对短期不感兴趣，我知道他是说 MiniMax 的，这个确实现在也不能说他赢了，智谱的输面非常大，但是未来两年能够挺得住，因为政府会挺他，MiniMax 甚至没有政府挺，那 MiniMax 的有可能赢最起码，但是要靠他是不是坚决的？不是，他的 CEO 说我准备去实现 AGI 之前不要工资，所以在全球化上不坚决，那你如果全球化不坚决，你在中国没空间。我们之前讲过了，独立大模型公司在中国很难生存，所以但是这逻辑和智谱是一样的，所以这两个公司不应该有那么大差异，这个分析我是不认可的，或者说这个市场反应我是不认可的。至少证明就是如果因为它要么都涨，要么都跌，一个涨一个跌就说明这个市场确实是存在市场愚蠢的。要么看这家公司是蠢的，要么看这家公司分析是蠢的，反正总之有市场愚蠢存在。但你不要问我市场愚蠢是什么，我不分析蠢人。第 SHEIN 未来增长主要会来自哪些业务和地区？是创造新增需求、继续替代竞争对手份额，还是向平台化和本地化扩张？海外监管会如何影响其增长上限？我本地化没看到他的特别强的需求，本地化理论上讲也可以做，因为其实中国人其实挺时尚化的，就 SHEIN 的打法在中国是可以做的。但是不知道他想不想本地化，本地化还有一个如何接受监管的问题，或者说他在海外上市了，是不是能够更愿意本地化一点，我都不知道，所以本地化不

知道，但是他海外是继续的。一个是他我之前我介绍过，我们研究的这个墨西哥的报道，就是他在美国已经平台化，则在北美已经平台化了。就是在墨西哥实现了小单快反的供应，主要为了供应美国市场。他在另一个地方是在土耳其做小单快反，想供应欧洲市场。所以它主要来自全球，当然全球的这个时装快时尚主，而欧美当然这个里面很好玩。原来曾经有过有一个公司，拓展某个国家市场的，自己不爱去，但是人家有人说我帮你拓展，那后来他们就答应了，就拓展的很成功，所以就是说呃理论上讲我觉得这个不客气，非洲也需要服装，也可以小单快反。如果说你能在非洲去建立小单快盘跟 SHEIN 谈，那我先在那做着，做到一定时候你能不能把我收购掉？我觉得 SHEIN 也可能会答应你，因为非洲市场千万不要忽视，这是一个挺好的市场的。包括我们就讲说，你看像这个 AI 生成视频，那 AI 生成短剧其实已经都做的相当逐渐越来越成熟了。你说是完美吗？还是差的远，但是越来越成熟了。现在你说这个 AI 短剧在美洲已经做了，在中国已经做了，哪没做？非洲人不看短剧吗？非洲已经有了这个传音了，当然传音是不是已经都做了短剧了，但是传音上没有 AI 生成短剧，为黑人兄弟们做的 AI 短剧，就是另一个也是很好玩，要和传音手机结合起来看，就是你 AI 生成的这个黑色的皮肤，黑色的脸能不能又清晰，又这个不别太糊了？那也是需求。而且这个非洲兄弟们喜欢的故事可能和我们亚洲兄弟不太一样，所以一样的道理就是都是机会，在我们眼里看都是机会。

然后这个图南说：端侧 AI 手机的功能似乎已经逐渐齐全，但普通大众的新增换机动力在哪里？如果到 2027 年底仍找不到旧手机无法完成的核心场景，端侧 AI 是否只是“更好的同一代手机”？判断产业进入展开期，应该看“懒惰需求被击穿”，还是出现真正“过去做不到”的能力？能力当然是都有啊，就是看什么懒惰能力，懒惰的能力被击穿，有时候反倒是更容易做的事儿。也就是说我比你现在做的更好，我不用掏手机了，或者掏手机说话就可以，做很多事儿就已经是够换机的理由了。但是我认为很多时候因为你换机的理由有时候不会充分在哪儿。那个手机特别好，你要得用一个苹果换一个苹果，苹果又没有足够的 AI 能力，所以我认为我愿意用一个千元机去补充我的苹果。顺便说我之前用过小米，我最近用的叫 IKK0。Echo 我原来说过还有一个方块方盒机，他终于寄到了。但是我这两天因为他太忙了，没来得及用的。我用跟大家汇报一下，那个就是个大

概两三千块钱的手机，但是它声称是全世界都能用，但是也是挺搞的。它声称全世界都能够访问这个访问 ChatGPT，因为我就有这个需求，结果我发现他到了中国以后，首先到处能上网上不了网的。因为他本来是在国外是 eSIM，理论上 eSIM 到哪都能上网，但是在中国不知道是不支持 eSIM 还是没有什么协议，反正我还得在里面插一中国卡，要不然他是中国没信号，你得只有在屋里有信号才能用 Wi-Fi 还挺搞的。但是理论上讲就是只要价钱合适，1000 元以内，中国人换机动力不足的话，这个单独购机动力也是可以的。

然后 Kevin 卢说：注意到 SHEIN 会从网站 APP 上搜集用户停留和点击数据合法吗？现在欧美，自己网站上收集是合法的，别人的网站收集是不合法的。

然后冰霞帮着总结的，今天晚上互动未解答的问题汇总，我挑两个来回答。大家都说是问 2，那我就回答二了。二的问题是庞老头的问题，王老师近两年在 AI 应用领域里是有可能是下一个腾讯？你看你们这个俗人，未来一定会出腾讯，我也一定会告诉大家。但是现在还没有明确的看到，所以或者说这么广泛的说，不见得是下一个腾讯。因为下一个腾讯做的微信，微信是两件事，一个是叫社交网络社交，另一个其实叫即时通讯，这两个领域都有可能，当然也可能是下一个合起来的应用，也可能是单独应用，但是一定会被改写。至少我看到社交会有大东西，但是现在还没看到，所以我认为这两三年会出来巨头，但是会出未来的巨头的小苗子，记不记得？我特别喜欢那个杜荀鹤的小松，这个叫自小刺头深草里，而今渐觉出蓬蒿。时人不识凌云木，直待凌云始道高。这个我们不用担心，现在那个小松连刺儿头都没有出蓬蒿都没有冒出头来的，甚至都还没有发芽。稍微等一等，这是乐趣。注意在等的时候不是瞎等是把规律彻底搞透。所以我特别想跟大家讲规律，因为只有现在才有时间静下心来研究规律，它都已经涨了，你得天天盯着人家浇水施肥，你哪有时间研究规律。但是问题就是说他没有的时候，你也不考虑规律，你瞎琢磨，等他有了以后，你也看不懂，所以这最幸福的，我认为我现在特别幸福。最幸福的就是说他没有的时候，你已经开始把规律搞得越来越透，越来越清楚了，当他有的时候你能够比别人更早的识别出来，然后你能伴随它成长，而且你能帮他成长，这是多大的乐趣，对不对？所以这个时候要问的是下一个腾讯的规律是什么？然后要问自己，如果下一个腾讯站出来了，你能不能识别出来好吗？一旦你能识别这个乐趣是我告诉你这个不可比拟的，比我告诉

你会乐趣对多多少，你会多快乐，好吧。对悦行远方说的非常对。现在是看的阶段，不着急，后面才是养的，三年之内把它看懂，然后你都能告诉煜全，我有把握了。如果下一个腾讯出来，我能够第一时间看懂，那你是好样的。这是我办特训营的目的，我的目的不是告诉你下一个腾讯是谁，我的目的是让你能够识别出下一个腾讯。

今天就这么多，又超了太多时间了。我们就下周再聊，下周应该是答疑时间了，因为现在答疑问题还挺多的，下周答疑我们集体答疑。Kevin 卢我觉得你这个足够勤奋，我觉得你应该能看出来，这两三年应该能看出来，人人都能看出来。只要你足够的勤奋投入，今天的因为前两次我给大家的礼物都好像都是这个艺术品，都是小小紫砂壶，什么小砚台，反应不积极。上次跟大家说，大家帮我们晒晒，收到的礼物也不给晒。所以我这回给大家科技一点，来两个这样的礼物。一个是他们送给我的 GAN 魔方，这个智能魔方本来送给我的我也不太擅长玩，老了手指不灵活。这个送给你们了，这个能够记下你每个动作，来修正你的魔方动作。希望你还有机会破这个魔方世界纪录，世界最好的魔方，也有我们的同学对吧？而且特别牛。原来我们去 CES 展，他跟我们一起去，然后到 CES 展一堆世界魔方爱好者飞到拉斯维加斯跟他见面。人家是魔方达人、魔方大牛、魔方大 V，他送的特别好啊，送给你了。

尤其是今天这个互动提问，我现场我觉得或者说最好就是悦行远方，尤其是第一个总结，我以后我也申请引用你的说法要换视角来理解。我觉得你这视角的观念特别好啊，申请换视角引用你的视角，我也会说的，还是我们同学叫悦行远方提出来的。但是你要告诉我真名，我就说是你的真名。你的观点特别好啊。就是技术站在工程师的角度，产业站在国家角度，应用站在用户角度，企业站在老板角度，悦行远方谢谢你，这个是你的了。

卓烜说：喜欢艺术品质，还在学习提问中。这学习没关系，我多的是艺术品，我这都预备了，不用担心。或者说有哪个艺术品，你说我能够提出好问题了，我保证我能提出好问题，能够中选，我就要这艺术品没问题，你点名我买给你。然后第二个是一个特好玩，我觉得好玩我就买了，都没来得及拆封，所以还完整的叫趣味陪伴小夜灯。就是晚上你叫他一声，他是一个盒子里这个你看盒子里的一只猫，但是它是会亮的。晚上它关上有个盒子关上灯就灭了。然后你叫他一声，

你要开夜灯的时候叫他一声，他要把这盒子打开，猫头探出来，就亮了，是一个夜灯，这个夜灯就给我们的那个现场回答，这个现场回答是谁的答案最好，或者谁的答案最有创造力，就冰霞来决定，这个是你决定发给谁，这个发给悦行远方好吧？那就这么多，我希望大家都有兴趣跟我探讨诗和远方，互动区奖品征集没人参与，没人参与，我都给事先提问了，那也行那都给事先提问的话，那刚才另一个提问我也觉得蛮好的，就是雨桐说尤其是从拜杜法案得到启发，我觉得这是我们特别思考的。就是要从 A 能够得到 B 启发，我们叫做历史是有韵脚的。从拜杜法得到启发是如何去社会分工，得到启发是在 AI 时代，人和人工智能也要分工。所以送给语桐好吧。

我希望我们有更多的有思想的人，希望有更多的思想的启发，我们是相互启发的，我希望成就大家，你也成就我。因为真的说实话，我看到两个特别好的问题，或者特别好的思考的时候，我特别兴奋。因为我觉得这是人才能享受的乐享受到的乐趣。动物没法享受这种思考的乐趣和互相启发的乐趣，人才能享受。人工智能时代，不该人干的事儿都会交给人工智能的。我们要去享受作为人的乐趣，每个人享受作为人的创造乐趣和享受作为人的分享的乐趣，和享受作为人的别人分享的精彩观点。而我能够与有荣焉的这个乐趣。针对奖品上提出问题的同学，申请名单里选取。当然你先最后变成那个中奖者，我可以给大家一个奖品清单，然后这个中奖者最后说我要哪个，这也可以操作，我现在这奖品一大堆。那今天先这样，今天这两个先发出去以后，我们按你说的改进好吧，那就这么多了，已经是十点半了，我得回家去了。我明儿又出差了，我们周末又有三天大课，好，拜拜大家。顺便说一定强调今天不是有人说需要总结。这个冰霞帮我记着的，因为之前咱有文字稿，差不多一周时间，会把文字稿就发出来了。然后冰霞帮我总结，就是文字稿前面在做一个浓缩的总结，可能就两页纸的总结，看大模型能不能做到，能做到发给大家一个精简版你说大家那么偷懒。

周末线下大课，我是现在每两个月上一次线下大课，是和我们合作伙伴叫大军集团来合作的。因为那个组织很麻烦很重，我不做组织的事，这别人在组织了。那我每两月上一次课，课的内容，每年都是更新一次，所以每年的这每两个月的课是差不多的。就是我们回顾一下我们的研究方法和我们的工业革命以来的技术进展，技术推动社会的整个的历史，然后同时对一些前沿同一些未来的一些思考。

所以三天基本上都是差不多的内容，但是我们每回的更换就是我们的思考，我自己学的也很快，参与的话就是单独报名，这个 2980 单独报名。可以问问他们是不是给蓝特运营同学有个折扣，别的没啥，但是我建议如果有空去参加一下线下课，因为三天时间的思考分析可以更系统。去美国可能要到 10 月份了，因为当时去美国十月份是长寿，是健康长寿。然后这科技的话就是明年 1 月份的 CES 考察。八月底对，我们两场。因为本来是每两个月 1 场，但是现在这个报名人数太踊跃了，所以又加了一场。本来是五月刚做完一场，七月这个周末做一场，然后九月但是实际上人太多了，所以八月做一场。然后八月完了以后可能就改成 10 月 12 月，这样就等于是本来是两个月 1 场，春节不做，所以一年五场，现在有可能变成一年六场，甚至如果年底人太多，改成一年七场都有可能。因为这也是好事儿，我们希望更多人都关注科技，关注创新。6 月 8 月在北京是的。

手环，我这之前其实发了一次，但是还没有完全准备好，所以现在他们正在加工，他们跟我说的是明天准备好啊，所以如果是明天能准备好的话，我们下周我就会开始正式推了。所以基本上反正就这几天，所以我们会有准备好了以后，产品完全 ready 以后，第一时间。刚才我们已经测了好几天了，已经都没事儿了。所以基本上这两天应该是就能确认说，反正因为我不干技术，他们技术人员要做完各种测试，告诉我说煜全你可以卖了，我就开始卖。下课报名就不是每次都会通知参加。是的，要跟他去谈那个大军组织我确实不太熟，就是你跟他去玩命喊呗。好，那这样，我们下次再聊，拜拜。